

# MediFlow

面向医疗数据治理、知识构建与自然语言分析  
的智能体系统

基于 Nexent 与 DataMate 的工程实现报告

---

## 技术报告

---

ModelEngine 开源项目贡献赛作品

# 目录

|                            |           |
|----------------------------|-----------|
| 摘要                         | IV        |
| <b>第一章 医疗数据治理背景与作品定位</b>   | <b>1</b>  |
| 1.1 医疗数据治理的赛题背景            | 1         |
| 1.2 MediFlow 系统定位          | 1         |
| 1.3 数据驱动的业务链路              | 1         |
| <b>第二章 MCP 工具封装与阶段数据链路</b> | <b>2</b>  |
| 2.1 平台职责边界与总体架构            | 2         |
| 2.2 阶段数据对象分层               | 2         |
| 2.3 智能体工具调用机制              | 3         |
| 2.3.1 DataMate 算子执行边界      | 4         |
| 2.4 任务角色与工具绑定              | 6         |
| 2.5 阶段数据标识与存储              | 7         |
| 2.5.1 三项任务之间实际传递什么         | 7         |
| 2.6 跨阶段执行链路                | 9         |
| 2.7 结果校验与执行边界              | 10        |
| <b>第三章 医疗数据治理智能体</b>       | <b>11</b> |
| 3.1 医疗数据治理目标               | 11        |
| 3.2 任务状态跟踪                 | 11        |
| 3.3 保持结构的文本治理              | 12        |
| 3.4 失败隔离与结果汇聚              | 14        |
| 3.5 PDF 文档适配               | 14        |
| 3.6 可追溯的数据交付               | 15        |
| <b>第四章 医疗知识构建与问答</b>       | <b>16</b> |
| 4.1 参考知识与增量数据接入            | 16        |
| 4.2 统一医疗记录解析               | 17        |
| 4.3 实体关系级联抽取               | 17        |
| 4.3.1 离线词典规则抽取             | 18        |
| 4.3.2 模型补充抽取               | 18        |
| 4.3.3 离线优先级级联抽取            | 19        |
| 4.3.4 基于可靠性分级的事实持久化        | 20        |
| 4.3.5 知识构建与问答路由            | 20        |
| 4.4 实体关系校验与入库              | 21        |
| 4.5 图谱事实的分析投影              | 22        |
| 4.6 知识图谱查询                 | 22        |
| 4.7 运行实例数据构成               | 22        |
| <b>第五章 面向业务问题的受控分析</b>     | <b>24</b> |
| 5.1 分析对象与访问入口              | 24        |
| 5.2 基于语义规划的查询路由            | 25        |
| 5.3 自然语言查询的只读执行            | 25        |
| 5.4 分析结果呈现                 | 26        |

|            |                        |           |
|------------|------------------------|-----------|
| 5.5        | 知识图谱的关系浏览              | 27        |
| 5.6        | 分析成果导出                 | 27        |
| <b>第六章</b> | <b>系统实现与部署</b>         | <b>28</b> |
| 6.1        | 系统运行的技术基础              | 28        |
| 6.2        | 代码模块组织                 | 28        |
| 6.3        | 平台接入与智能体发布             | 29        |
| 6.4        | 系统部署架构                 | 30        |
| 6.5        | 项目交付资产                 | 30        |
| 6.6        | 基于异常记录的故障定位            | 31        |
| <b>第七章</b> | <b>系统验证与性能评测</b>       | <b>32</b> |
| 7.1        | 评测范围与数据来源              | 32        |
| 7.2        | 智能体工具调用验证              | 32        |
| 7.3        | 任务一输入路由测试              | 33        |
| 7.4        | 任务一算子清洗评测              | 33        |
| 7.5        | 任务二抽取回归测试              | 35        |
| 7.5.1      | 真实文本入口与跨任务衔接验证         | 36        |
| 7.6        | 任务二抽取质量与耗时评测           | 37        |
| 7.6.1      | 评测数据与执行口径              | 37        |
| 7.6.2      | 固定留出集基线                | 37        |
| 7.6.3      | 级联抽取同批对照               | 37        |
| 7.7        | 双库数据一致性核验              | 39        |
| 7.8        | 在线查询验证                 | 39        |
| 7.9        | 任务三 NL2SQL 执行评测        | 40        |
| 7.10       | 分阶段性能控制                | 41        |
| <b>第八章</b> | <b>关键技术创新</b>          | <b>43</b> |
| 8.1        | DataMate 数据与算子的 MCP 封装 | 43        |
| 8.2        | 阶段标识驱动的结果追踪            | 43        |
| 8.3        | 统一分析结果的多端复用            | 44        |
| 8.4        | 离线优先的级联抽取              | 44        |
| 8.5        | 基于审计差异的语义噪声规则学习与复用     | 45        |
| 8.6        | 保持结构的数据处理              | 45        |
| 8.7        | 多层只读查询防护               | 46        |
| <b>第九章</b> | <b>开源协作与工程交付</b>       | <b>47</b> |
| 9.1        | 团队职责与工程产出              | 47        |
| 9.1.1      | 成员 A：需求与医学建模           | 47        |
| 9.1.2      | 成员 B：数据资产与语料治理         | 47        |
| 9.1.3      | 成员 C：算法与算子研发           | 47        |
| 9.1.4      | 成员 D：平台集成与部署           | 47        |
| 9.1.5      | 成员 E：测试、复现与交付          | 47        |
| 9.2        | 上游能力调研与方案选型            | 48        |
| 9.3        | 开发验证流程                 | 48        |
| 9.4        | 上游平台接入与项目功能边界          | 49        |
| 9.5        | 代码仓交付结构                | 49        |
| <b>第十章</b> | <b>系统运维方案</b>          | <b>50</b> |

|                          |           |
|--------------------------|-----------|
| 10.1 运行维护重点 . . . . .    | 50        |
| 10.2 质量与性能维护规范 . . . . . | 50        |
| <b>附录 A 系统资产清单</b>       | <b>51</b> |
| A.1 任务一数据处理资产 . . . . .  | 51        |
| A.2 任务二知识构建资产 . . . . .  | 52        |
| A.3 任务三分析工具 . . . . .    | 53        |
| A.4 数据库与结果文件 . . . . .   | 54        |
| <b>参考文献</b>              | <b>54</b> |

# 摘要

医疗资料同时包含自由文本、表格、JSON 记录和 PDF 文档。赛题要求智能体完成数据处理、知识构建和自然语言分析，并使各阶段产物可查询、可校验。MediFlow 以 Nexent 为对话入口，通过 MCP 将智能体的任务级规划与 DataMate 的数据集、算子和任务执行连接起来。

系统沿“数据处理 → 知识构建 → 分析查询”组织三项任务。任务一保留输入数据的字段、键名和记录边界，将文本治理结果登记为交付数据集。任务二将清洗记录转为实体、关系和三元组，经离线优先的级联抽取、否定识别、可靠性分级和来源证据校验后写入图谱。任务三由统一分析服务承接 Nexent 对话和 Web 工作台入口，根据医疗语义和数据表生成查询计划，在只读连接、允许查询对象清单和执行时限约束下形成分析结果。

三个智能体均采用“智能体选择任务级工具、服务确定阶段内执行路径”的分工。工具调用负责表达任务意图，服务和算子负责完成确定性处理，来源、运行状态和分析结果通过统一标识关联。

在固定留出集上，离线实体识别使用 2500 条 CMeEE 样本，F1 为 37.70%；离线关系抽取使用 1793 条 CMeIE 样本，F1 为 14.31%。任务三另以实际分析库构建 133 道 NL2SQL 题，固定测试集的初始配置执行准确率为 61.3%，优化配置验证结果为 95.7%。报告同时给出抽取质量、查询准确率、在线响应时间和数据规模，使三项任务的处理效果与服务能力具有统一的量化依据。

**关键词：**医疗数据治理；MCP；智能体；知识图谱；自然语言数据分析；DataMate；Nexent

# 第一章 医疗数据治理背景与作品定位

## 1.1 医疗数据治理的赛题背景

ModelEngine 面向数据处理、知识生成和智能体应用提供开源工具链。DataMate 管理数据集、文件和算子任务，Nexent 管理智能体配置、工具绑定和对话执行。作品需要在两套平台之间建立可运行的医疗业务链路，完成数据处理、知识构建与问答、数据分析三个任务，并交付可核验的结果。

医疗资料同时包含自由文本、结构化表格、JSON 嵌套对象和 PDF 文档。实体、关系和来源信息分散在不同记录中，分析结果还需要以文字回答、统计图表和文件形式交付。

MediFlow 围绕三个赛题问题组织工程方案。数据处理阶段由智能体判断探查、处理和状态查询意图，服务根据数据状态选择格式处理链；知识构建阶段将记录转换为带来源的实体关系，经分级和校验后写入图谱；分析阶段把用户问题映射到图谱事实、分析表或只读查询，并生成可追踪的成果记录。

系统当前处理医学知识资料和聚合统计，定位为面向知识资料的工程系统。现有数据没有可用时间维度，分析结果按知识条目和关系事实解释。本文的系统对象包括三部分：MediFlow 提供 MCP 工具和医疗领域处理服务，Nexent 中的三个智能体负责任务级规划，DataMate 负责数据集和算子执行。

## 1.2 MediFlow 系统定位

MediFlow 是连接 Nexent 与 DataMate 的医疗数据处理与知识分析系统。系统把 DataMate 的数据集、算子和任务接口封装为 MCP 工具，再由领域服务补充格式路由、实体关系校验、图谱写入和只读查询规则。Nexent 中的三个智能体分别面向数据处理、知识图谱和数据分析；它们共享服务入口，并按职责限制可见工具和回复范围。

本文后续统一使用以下称谓：MediFlow 指本项目系统，MediFlow 服务指提供 MCP 接口的服务进程，智能体指 Nexent 中的任务配置，工具指智能体可调用的 MCP 接口，算子指 DataMate 执行的单步数据变换。系统输出中的“处理记录”保存文件状态、阶段统计和质量字段；“来源记录”保存数据集、文件和知识来源；“分析结果记录”保存问题、查询计划、SQL、数据行、图表配置和来源信息。

## 1.3 数据驱动的业务链路

作品沿“数据处理 → 知识构建 → 分析查询”的业务链路组织三个阶段。数据处理阶段接入原始资料，完成文本治理和结构保持后登记交付数据集；知识构建阶段读取交付数据集，抽取实体关系，经分级、校验和去重后写入知识图谱，并刷新分析库；分析查询阶段读取图谱和分析库，生成回答、图表和导出文件。

# 第二章 MCP 工具封装与阶段数据链路

## 2.1 平台职责边界与总体架构

MediFlow 把任务理解、领域编排和平台执行分成三个边界。Nexent 识别用户目标并选择任务级工具；MediFlow 校验参数、读取数据状态并选择处理流程；DataMate 执行数据集任务和单步算子，知识库与分析库负责持久化。三个智能体各自只绑定职责相关的工具；工具可以跨角色复用，但任务一、任务二和任务三的写入边界彼此独立。

三个阶段通过四类标识衔接：DataMate 数据集标识确定输入和交付数据集；任务一运行标识跟踪后台处理；任务二来源标识和记录标识定位文件与图谱记录；任务三分析标识关联问题、查询结果、图表和导出文件。用户既可分别使用三个智能体，也可将任务一产生的数据集直接交给任务二，再由任务三读取图谱及分析表完成查询。

## 2.2 阶段数据对象分层

图 2.1 给出了访问入口、专业智能体、领域服务和阶段数据对象的对应关系。访问入口包括 Nexent 对话和 Web 工作台；三个智能体分别负责数据处理、知识图谱和数据分析；领域服务承担格式路由、抽取校验、语义规划与查询执行；数据对象层保存交付数据集、知识图谱库和分析结果。




图 2.1 MediFlow 的智能体、服务与数据对象结构

DataMate 提供数据集、文件、算子和任务管理功能<sup>[1]</sup>。Nexent 提供智能体配置、工

具绑定、版本发布和对话执行功能<sup>[2-3]</sup>。项目使用 Model Context Protocol 连接 Nexent 与工具服务<sup>[4]</sup>，在此基础上实现医疗格式路由、抽取校验、图谱持久化、查询安全和成果生成。任务三由统一分析服务承接正式查询链路。Nexent 任务三智能体和 Web 工作台都把自然语言问题交给该服务；服务统一完成语义规划、只读执行、结果记录、图表组织和成果导出。图谱数据库提供事实与来源，分析数据库提供统计查询，两类数据在统一分析结果中按用途关联。

### 2.3 智能体工具调用机制

智能体把用户任务转换为结构化工具调用，不直接执行文件处理、数据库写入或 SQL。图 2.2 展示一次调用的边界：Nexent 根据职责提示和工具说明识别任务类型，以工具名称和参数发起请求；FastMCP 将请求转交给 MediFlow 服务；服务按参数和数据状态选择处理流程，并把状态、产物标识和处理记录返回给智能体。




图 2.2 智能体单次调用的分层过程

三个智能体使用不同的工具集合和职责规则。职责提示规定任务范围、工具调用顺序、参数来源和回复格式；约束提示规定只读边界、错误处理和禁止虚构结果；工具说明向模型提供接口名称、参数和返回字段。模型据此选择任务级入口，而不是直接决定每一个底层算子。例如，任务一由智能体选择 `run_task1_mixed_cleaning`，服务再按文件类型建立 DataMate 子任务和算子链。

工具返回的结构化状态决定后续动作。小数据集完成后直接返回交付数据集，大数据集返回运行标识并等待状态查询；任务二返回抽取和入库状态，任务三返回查询计划、

数据行和分析标识。工具调用失败时，智能体依据错误字段说明失败阶段和下一步。




图 2.3 任务级工具到内部处理分支的映射

2.3.1 DataMate 算子执行边界

DataMate 算子承担单步数据变换。项目算子采用 DataMate 的 Mapper 接口，由 `execute` 接收样本字典或文件记录，返回更新后的字段和处理记录；`metadata.yml` 保存注册信息。MediFlow 根据文件格式或抽取后端建立算子计划，DataMate 执行单步算子并返回结果；Nexent 只选择任务级 MCP 工具，不直接指定底层算子。

表 2.1 归纳项目中的算子类别和执行边界。

表 2.1 MediFlow 算子类别与执行边界

| 类别   | 代表算子                                                                   | 主要结果                      |
|------|------------------------------------------------------------------------|---------------------------|
| 通用清洗 | EmojiCleaner、UrlRemover、Whitespacenormalizer 等平台清洗算子                   | 字符、链接、空白和文档噪声治理           |
| 医疗治理 | MedicalTermNormalizer、MedicalTextQualityFilter、LLMNoiseFilter          | 术语替换、质量筛选和噪声处理记录          |
| 结构保持 | TableColumnCleaner、JsonFieldCleaner                                    | 按字段清洗，保留表头、键名和嵌套层次        |
| 知识抽取 | MedicalEntityExtractor、MedicalRelationExtractor、MedicalTripleGenerator | 实体关系抽取和三元组生成              |
| 记录组织 | MedicalRecordSplitter                                                  | 按段落和句子边界拆分医疗记录，保留源文件与分段序号 |

任务一在线流程直接创建 DataMate 清洗任务并轮询状态。任务二的算子目录提供可注册的抽取资产，当前在线建图入口由 `run_task2_kg_pipeline` 调用共享抽取服务，再完成校验、入库和分析表刷新；两条路径共用实体关系模型和校验模块，运行边界分别由 DataMate 任务和任务二领域服务负责。

任务级工具负责选择处理能力，MediFlow 服务负责把参数映射为算子链或领域服务，阶段产物统一回到带有状态和来源的结果记录。

一次完整调用还包含明确的时序关系：智能体先选择任务级工具，FastMCP 再转发结构化参数，MediFlow 服务调用 DataMate 算子或只读查询，最后沿原路径返回状态和产物标识。图 2.4 展示了这一过程。




图 2.4 智能体、MCP 服务与执行后端的调用时序

## 2.4 任务角色与工具绑定

项目按数据、知识和分析划分三个专业角色，表 2.2 从用户任务、执行逻辑和产物三个角度说明职责。Nexent 配置决定智能体可见的工具集合，MediFlow 服务负责参数校验和阶段内执行，DataMate 负责数据任务。三个已发布角色覆盖赛题流程，自定义智能体也可复用其中的单项或组合工具。

表 2.2 三个智能体的职责与工具边界

| 专业角色      | 用户任务                      | 核心执行逻辑                               | 主要产物                      |
|-----------|---------------------------|--------------------------------------|---------------------------|
| 医疗数据处理    | 探查数据集、启动处理、查询进度、取得结果      | 识别五类文件，创建格式子数据集，运行 DataMate 算子链并汇聚结果 | 交付数据集、文件状态与处理报告           |
| 知识图谱生成与问答 | 从数据集建图、从文本抽取、查询疾病事实和关系    | 把文件解析为记录流，合并本地与模型抽取，校验后增量入库并刷新分析表    | 来源、实体、关系、三元组和疾病分析表        |
| 数据分析与可视化  | 查询疾病属性、统计关系分布、核对来源、导出分析成果 | 优先使用医疗语义模板规划查询，校验只读 SQL，组织回答、图表和报告   | 分析结果记录与 HTML、CSV、JSON 成果包 |

## 2.5 阶段数据标识与存储

系统根据数据的使用方式设置三类存储。DataMate 保存待处理文件、算子任务和交付数据集；知识图谱 SQLite 库保存规范化实体关系及其来源；分析 SQLite 库保存面向疾病查询的关系表和统计视图。任务三执行过程中生成一条分析结果记录。表 2.3 列出各层的实际结构。

表 2.3 核心存储与阶段数据对象

| 对象           | 主要结构                                                                        | 作用                   |
|--------------|-----------------------------------------------------------------------------|----------------------|
| DataMate 数据集 | 数据集标识、文件清单、算子实例、清洗任务、目标数据集                                                  | 承载任务一输入、分格式处理和最终交付   |
| 知识图谱库        | kg_sources、kg_entities、kg_aliases、kg_relations、kg_triples、kg_quality_issues | 保存实体关系、原文片段、来源和质量记录  |
| 分析数据库        | diseases、disease_facts、9 张疾病关系表、统计表与统计视图                                    | 支持疾病属性查询、分布统计和图表生成   |
| 分析结果记录       | 分析标识、问题、查询计划、SQL、数据行、图表配置和来源信息                                              | 统一驱动文字回答、结果表、图表和成果导出 |

### 2.5.1 三项任务之间实际传递什么

三项任务之间不传递一句笼统的“处理结果”，而是传递可检查的数据对象和标识。任务一仍以 DataMate 数据集交付文件；任务二读取文件后才在内存中转换为统一记录；任务三读取任务二已经提交的图谱库和分析库。表 2.4 给出实际格式和追溯字段。

表 2.4 三项任务的数据格式、传递方式与追溯标识

| 阶段           | 实际交付格式                                     | 下一阶段如何读取                                                                          | 追溯字段                                                                                                              |
|--------------|--------------------------------------------|-----------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| 任务一 →<br>任务二 | TXT、CSV、<br>JSON、JSONL；<br>PDF 解析后为<br>TXT | 以最终 <code>dataset_id</code> 读取<br>文件；TXT 按段落、CSV<br>按行、JSON 按对象、<br>JSONL 按行转换为记录 | 源数据集、最终数据集、文件名、<br>格式、任务运行标识                                                                                      |
| 任务二内<br>部    | <code>records[]</code> ，每条含<br>文本和来源字段     | 同一抽取服务读取 <code>text</code> ，<br>并按源文件轮转抽样；不<br>把原文件物理改写成<br>JSONL                 | <code>source_file</code> 、 <code>source_format</code> 、<br><code>record_id</code> 、 <code>source_record_id</code> |
| 任务二 →<br>任务三 | SQLite 图谱表及由<br>图谱刷新得到的分<br>析表             | 实体关系查询读取图谱；<br>统计、排名和分组读取分<br>析表                                                  | <code>source_id</code> 、源文件、源记录、<br>原文证据、抽取方式、可靠等级                                                                |
| 任务三 →<br>用户  | 分析结果记录、<br>HTML、CSV、<br>JSON               | 同一分析标识驱动回答、<br>表格、图表和导出                                                           | <code>analysis_id</code> 、查询计划、SQL、<br>结果行和来源字段                                                                   |

一条事实的追溯路径可以直接读成：

最终数据集 `dataset_id` → 源文件 `source_file` → 记录 `record_id` → 三元组及  
`evidence` → 任务三查询结果与 `analysis_id`

结构化文件中如果原记录自带 `record_id` 或 `id`，任务二将其保存在 `source_record_id`；否则使用“文件名: 行号或分段号”生成稳定记录号。三元组入库时同时保存数据集来源、文件名、记录号和原文片段，所以任务三返回一条关系时可以定位到任务一交付数据集中的具体记录，而不只知道它来自“某个知识库”。

图 2.5 展示了知识图谱库与分析数据库之间的数据对象关系。任务一交付数据集先登记来源，图谱库再维护实体、关系、三元组和质量记录；规范化三元组投影为疾病事实 and 关系表，任务三据此生成分析结果记录。




图 2.5 知识图谱与分析数据对象关系

知识图谱库适合维护规范化实体、关系和事实来源，分析数据库则按关系类型把三元组转换为疾病与症状、药物、检查、科室等直接可查的业务表。这种双库结构使任务二可以按事实粒度增量写入，任务三可以使用简单、稳定的 SQL 完成聚合查询。

## 2.6 跨阶段执行链路

一次完整业务过程由以下六步组成：

1. 用户在 DataMate 准备资料数据集，数据处理智能体先读取文件清单与格式分布；
2. 任务一按格式建立子数据集，执行相应算子链，并登记新的交付数据集；
3. 任务二按源文件轮转读取记录，避免处理上限集中落在单个文件；
4. 抽取结果经实体位置、类型、关系引用和置信度校验后写入图谱事务；
5. 新增三元组写入成功后刷新疾病事实表、九类关系表和统计视图；
6. 任务三通过统一分析服务使用语义模板或经过约束的查询计划访问分析库，生成回答、数据表、图表和导出文件。

这套流程允许单独运行任一任务。已有公开医学资源可直接构成基础知识图谱，新接入资料则沿任务一、任务二进入同一图谱，任务三使用统一的数据口径展示已有知识与新增知识。

## 2.7 结果校验与执行边界

任务一在结果汇聚前重新解析 JSON、JSONL 和 CSV 产物，PDF 分支分别保存上传、解析、下载和正文转换状态；文件数超过 50 时转为后台任务并返回运行标识。任务二只接收九类医疗实体和关系映射表中的关系，实体必须能在原文中定位。抽取结果先按可靠性等级分为高、中、低三级，再分别进入主图谱、候选记录或拦截记录；通用三元组转换函数的 0.7 参数是默认下限，在线级联入口显式保留候选，由持久化规则完成最终分流。任务三只允许访问安全白名单中的 17 个查询对象（14 张表和 3 个视图），SQL 必须为单条 SELECT 或 WITH 语句，数据库连接启用只读与 `query_only`，单次最多执行 4 项查询、每项最多返回 200 行并设置 5 秒中止条件。这些控制直接嵌入处理链和数据库访问层，Nexent 和 Web 工作台都经过同一分析服务并采用同一执行规则。

# 第三章 医疗数据治理智能体

## 3.1 医疗数据治理目标

医疗数据处理智能体向用户提供数据集探查、文件上传、医疗内容处理和状态查询。当前发布配置绑定 5 项工具，覆盖文本上传、数据集检查、算子查询、混合处理和进度查询。用户提交 DataMate 数据集名称或标识后，服务解析为平台数据集标识，读取处于可处理状态的文件清单，再按文件内容与扩展名确定处理分支。任务一的目标是登记可供知识抽取的交付数据集，并同时返回规范化文本、原有字段结构、文件级处理状态、质量记录和来源记录。

任务一接收 TXT、CSV、JSON、JSONL 和 PDF 五类输入，其中 Markdown 按文本处理，TSV 按表格处理。系统把文件识别、格式分组、医疗内容处理、DataMate 子数据集创建、算子任务执行、结构恢复、质量检查和交付数据集登记组织为一条服务流程，见图 3.1。




图 3.1 医疗数据处理流程

## 3.2 任务状态跟踪

探查服务按 DataMate 文件记录读取文件名、类型和预览内容，汇总五类格式的文件数，并把未支持文件保留在结果清单中。Nexent 根据用户表达选择“查看数据集”“启动处理”或“查询运行状态”；进入处理后，具体算子组合由服务端格式映射表决定。同一批文件因此只产生一份任务级计划，计划中列出每个格式分组、所用算子链、临时数据集和目标文件形式。

同步处理适用于不超过 50 个文件的数据集。文件数更大时服务建立后台运行记录并立即返回运行标识，状态查询依次给出排队、运行、成功或失败，使长任务不占用一次对话请求。

任务一智能体按用户表达区分三类动作：查看数据集时调用 `inspect_dataset`，执行混合格式清洗时调用 `run_task1_mixed_cleaning`，查询后台进度时调用 `get_task1_mixed_cleaning_status`。用户直接提供原始文本时，智能体先调用 `upload_text_to_datamate` 取得真实数据集标识，再把该标识传给数据集探查和清洗工具。

智能体只负责选择任务级工具并传递真实标识。工具服务读取文件清单后，由格式

映射表决定文本、表格、结构化文件和 PDF 的处理链，因此模型不会绕过结构校验直接指定算子。工具返回 `run_id` 时，智能体继续查询状态；返回错误时，回答保留错误阶段和已完成分组，部分产物仍按服务状态标记。

### 3.3 保持结构的文本治理

五类格式共享字符级基础治理，包括表情符号、URL、乱码、不可见字符、全半角、繁简体、HTML 标记和空白规范。文本分支继续执行长度、重复短语、特殊字符和重复文件过滤，再进行医疗术语与缩写规范、语义噪声处理。

任务一中的专业领域异常，主要指会干扰医学事实识别的异常表达，而不是把异常检验值擅自改成“正常值”。系统会处理乱码、不可见字符、全半角和繁简体混用、HTML 与 URL、Emoji、HIS 导出标记、测试标记和调试元数据，也会检查过短或过长文本、重复片段、特殊字符比例过高和重复文件等低质量内容。清洗只改写格式问题和明确的非医疗噪声；症状、否定词、药物、用法用量、医学数值、姓名和病历号作为需要保护的内容参与复核。结构化输入只处理文本字段，键名、列名、记录边界和非文本值保持不变。

结构化分支只清理文本字段，并在结果汇聚阶段恢复原有结构。

医疗术语规范由 `MedicalTermNormalizer` 算子执行，采用词典优先、LLM 兜底的混合策略。词典数据来自瑞金糖尿病研究中的医学术语和通用医学缩写库，共 114 条映射（`operators/medical\_term\_normalizer/term\_kb.db`），覆盖“T2DM→2 型糖尿病”“AMI→ 急性心肌梗死”等高频缩写。词典命中后直接替换，未覆盖的缩写交由 LLM 补充处理，LLM 调用失败时退回词典结果。算子返回每条替换的原文、替换后文本和出现次数。这一步解决同一医学概念在病历中以全称、缩写或单位变体出现时难以合并的问题。词典优先保证高频映射稳定、可复现，LLM 只补充词典未覆盖的长尾缩写；术语标准化负责统一表达，语义噪声过滤负责删除非医疗内容，二者不互相替代。

这里的语义噪声，是指混在医疗正文中的闲聊、科室交接、通知或模板化备注。它与 URL、HTML 和 Emoji 等可按字符模式识别的固定噪声不同，本身往往是通顺句子，直接按关键词删除可能误伤症状、否定词或医学数值。语义噪声处理由 `LLMNoiseFilter` 算子执行。该名称沿用算子注册名，当前实现读取 SQLite 规则库（`operators/llm\_noise\_filter/noise\_kb.db`）中通过审核并启用的规则。规则素材来源于 cMedQA2 中文医疗问答社区数据，覆盖广告营销、联系方式、系统导出标记、测试数据标记、网页尾部信息和 URL 链接等噪声类型。算子将文本逐条匹配规则，命中段落按规则指定的范围（行、句子或文本块）移除，并记录拦截类型、匹配规则和移除内容，形成文件级质量记录。规则库独立于算子代码，新增规则只需更新数据库，无需修改算子逻辑或重新注册。

固定规则无法提前列出病历中不断出现的闲聊和交接文字。系统因此记录教师清洗前后的差异，并从历史差异中寻找重复片段。同一片段至少出现 3 次、类别位于安全清单、且不含疾病、症状、药物或医学数值时，系统才将它写入规则库。后续文件直接复

用该规则，不再重复调用模型。这项机制学习的是经过确认的重复噪声模板，不把未见表达误报为已经掌握的语义能力。

服务只报告算子实际返回的处理项，不根据提示词推测清洗效果。字符变化、解析错误、空文本、重复内容和结构复核共同组成文件级质量摘要。

服务端在 `mcp_server/task1/chains.py` 中维护格式到算子链的映射。文本和 PDF 复用基础清洗、文档质量检查、`MedicalTermNormalizer` 与 `LLMNoiseFilter`；CSV 进入 `TableColumnCleaner`，JSON 和 JSONL 进入 `JsonFieldCleaner`。PDF 先由 `MinerU` 转换为 TXT，再复用文本链，因此 PDF 解析属于输入适配，医疗内容治理仍由 `DataMate` 算子完成。

表 3.1 医疗内容治理与结构处理方式

| 格式    | 处理单元与算子组合                                  | 交付结构                 |
|-------|--------------------------------------------|----------------------|
| TXT   | 整篇或分段文本；基础治理、文档质量过滤、医疗术语与缩写规范、语义噪声处理       | 合并分段并输出 TXT          |
| CSV   | 保留表头与行列位置；基础清理后执行表格列清理                     | 保持列名、列顺序和 CSV 格式     |
| JSON  | 递归处理对象与数组中的文本值；基础清理后执行 JSON 字段清理           | 保持键名、嵌套层次和 JSON 对象结构 |
| JSONL | 逐行解析对象并清理文本字段                              | 保持一行一条 JSON 记录       |
| PDF   | <code>MinerU</code> 提取正文并转换为文本，再执行 TXT 处理链 | 以同名 TXT 作为交付文件       |

图 3.2 把五类输入的处理单元、格式专用步骤和交付结构展开到字段层面。公共交付步骤负责结构恢复、重新解析检查和文件状态登记，因此任务二能够沿同一数据集标识读取清洗结果。




图 3.2 五类输入的格式专用处理与结构保持结果

文本算子可能产生带序号的分段文件，汇聚服务按原文件名和分段序号重新合并；JSON 与 JSONL 结果恢复扩展名后再次解析，CSV 结果重新读取表头。完成结构检查的文件进入最终数据集，任务二可以继续按字段读取结构化资料。

任务一与任务二的交接单位是“最终数据集标识”，不是一段复制粘贴的文本，也不是强制统一成 JSONL。任务二根据该标识读取文件清单：TXT 和 PDF 转换文本按段落形成记录，CSV 每行形成记录，JSON 数组每个对象形成记录，JSONL 每个非空行形成记录。每条记录均附带源文件名、源格式和稳定记录号；结构化文件中原有的 record\_id 或 id 另行保留。因此，任务一既能保持 CSV 表头和 JSON 键结构，也能让任务二使用同一个抽取入口处理五类来源。

### 3.4 失败隔离与结果汇聚

混合编排服务先按五类格式建立临时子数据集，再为每个非空分组创建 DataMate 清洗任务。任务返回目标数据集后，服务读取实际产物并完成分段合并、扩展名恢复和结构检查。各分组采用独立任务，某一格式失败时仍可保留其他分组的完成结果和文件状态。

最终交付数据集由各格式分组的合格产物重新汇聚而成。服务将这些产物登记到一个 DataMate 数据集中，同时返回源数据集、格式分组、算子方案、子任务、目标数据集、文件级报告、处理性能和治理元数据。这些字段共同说明“处理了哪些文件、经过哪条链、产物存放在哪里”，并为任务二提供可直接解析的数据集标识。

### 3.5 PDF 文档适配

PDF 是任务一的文档输入适配分支，不改变后续医疗内容治理逻辑。项目通过 MinerU 接口完成版面解析和正文提取<sup>[5-6]</sup>，客户端负责文件上传、任务轮询和结果下载。服务从解析产物中选择正文 Markdown，去除版式标记后生成 TXT 文件，再进入与普通文本相同的 DataMate 算子链。

当前适配器单次处理一份 PDF，上传前检查文件有效性、10 MB 大小限制和 20 页

页数限制，并为上传、轮询、结果下载、正文缺失和超时分别返回状态。PDF 结果明确标记为文本交付，其他格式继续保持源格式。正文解析结果通过 Markdown 语法树提取段落与表格文字，链接和图片标记在进入文本清洗链前被移除。

### 3.6 可追溯的数据交付

表 3.2 医疗数据处理智能体的交付内容

| 交付项    | 主要内容                                 | 后续用途             |
|--------|--------------------------------------|------------------|
| 交付数据集  | 清洗后的 TXT、CSV、JSON、JSONL 文件及 PDF 转换文本 | 作为任务二知识抽取输入      |
| 分组任务结果 | 各格式子数据集、DataMate 任务、算子方案和目标数据集       | 查看平台任务与分支执行状态    |
| 文件处理记录 | 源文件、识别格式、输出文件、完成状态和处理信息              | 定位单个文件的处理结果      |
| 质量摘要   | 文件数、记录数、术语替换、噪声处理、格式检查和结构恢复结果        | 核对交付数据是否满足后续读取要求 |

任务一把文件级算子执行组织为数据集级治理交付：用户在 Nexent 中发起一次任务，DataMate 承载多个格式子任务，项目服务负责结构保持与结果汇聚，最终得到可直接进入知识抽取的数据集入口和可核验的处理记录。

## 第四章 医疗知识构建与问答

任务二以任务一产出的清洗数据集为输入，经过记录解析、实体关系抽取、校验去重和图谱持久化，生成可查询的医疗知识图谱，并同步刷新面向分析查询的派生表。智能体同时绑定建图工具和查询工具，用户可以在一次对话中完成从数据集到图谱查询的完整流程。

### 4.1 参考知识与增量数据接入

图谱的基础知识层由两个外部数据源和一个内部质检参考共同构成，通过 `kg/build\_kg\_v2.py` 统一写入 SQLite。

**QASystemOnMedicalKG（图谱主体）。**这是一个开源中文医学知识图谱项目<sup>[7]</sup>，其核心文件 `medical.json` 以 JSONL 格式收录了 14 408 种疾病的结构化信息，每种疾病携带症状、药物、检查、科室、并发症、病因、预防等字段。构建脚本逐行解析后，按字段到关系的映射表（如 `symptom`→ 临床表现、`recommand_drug`→ 药物治疗、`check`→ 检查、`cure_department`→ 就诊科室）将每条字段值拆分为三元组写入图谱，贡献 420 221 条三元组。写入过程中对症状字段执行质量检查：以从 CMeIE 标注数据中提取的症状词汇表为参照，筛除不包含典型症状字眼且不在词汇表中的条目（如人名、乱码、数据污染），被筛除的条目写入质量记录表而不进入图谱。

**CMeIE 标注数据（关系补充）。**CMeIE 是 CBLUE 基准中的中文医学信息抽取数据集<sup>[8]</sup>，包含 14 339 条已标注实体和关系的句子。构建脚本将标注的实体对和关系类型通过 `CMEIE_RELATION_MAP` 映射为项目的 15 类标准关系后入库，贡献 25 046 条三元组。此外，CMeIE 定义的 43 种关系类型和实体类型体系也是后续抽取校验模块中类型合法性的判断依据（`core/medical\_extraction\_validation.py` 的 `ENTITY_TYPES` 和 `CMEIE_RELATION_TYPES`）。

**CMeEE 标注数据（质检词典）。**CMeEE 同样是 CBLUE 的标注数据，用于实体识别评测。在离线构建阶段，构建脚本从中提取全部已标注的症状实体，形成一份“确认是症状”的词汇表，用于过滤 `medical.json` 中质量存疑的症状字段。CMeEE 本身不直接导入图谱，而是作为质检参考标准参与基础知识层的质量把关。

三者的分工是：QASystemOnMedicalKG 提供覆盖面，CMeIE 提供标注精度，CMeEE 提供质检依据。基础构建程序还定义了 15 类标准关系，以关系代码和中文显示名分开保存，使不同数据来源中的“临床表现”“相关症状”等表达归并到统一查询口径。

基础知识层构建完成后，任务一交付数据集进入任务二处理流程时，每次处理都注册独立来源，新增事实沿用同一套实体、关系和三元组表结构，增量数据与基础知识共用同一查询和分析入口。当前在线实例中，增量管道累计贡献 553 条三元组，作为独立来源（DataMate 增量）与基础知识共存于同一统计口径。

## 4.2 统一医疗记录解析

任务二处理流程的第一步是将 DataMate 数据集中的清洗后文件转换为统一的记录流。共享解析模块按文件扩展名和内容类型分派处理：TXT 以空段落切分，单段超过 1200 字符时按句号边界继续拆分；CSV 经 `csv.DictReader` 逐行序列化，保留列名作为字段键；JSON 数组逐项生成记录，对象整体作为一条；JSONL 按非空行逐条解析。每条记录统一携带 `record_id`、`source_file`、`source_format` 和原始字段；结构化记录原本带有 `record_id` 或 `id` 时，另存为 `source_record_id`，否则使用源文件名加行号或分段号生成稳定记录号，确保下游抽取模块无需区分原文件的物理格式。

当用户通过 `max_records` 参数限制单次处理量时，选择模块采用跨文件轮转抽样：按源文件分桶后轮流从各桶取一条，使处理额度在各文件之间均匀分配。例如 5 个文件各 100 条记录、限制 50 条时，每个文件贡献 10 条。




图 4.1 清洗数据集到知识图谱和分析表的处理流程

## 4.3 实体关系级联抽取

统一抽取服务提供三种可切换的后端。

任务二的 DataMate 算子把记录处理拆成可注册的单步处理。表 4.1 给出算子接口与在线建图服务的对应关系。

表 4.1 任务二算子接口与处理结果

| 算子                           | 输入与处理                      | 输出字段                              |
|------------------------------|----------------------------|-----------------------------------|
| MedicalEntity<br>Extractor   | 读取记录文本，按离线、模型或混合后端识别九类医疗实体 | <code>entities</code> 、后端标识和抽取耗时  |
| MedicalRelation<br>Extractor | 结合实体结果抽取疾病与其他实体之间的关系       | <code>relations</code> 、后端标识和抽取耗时 |
| MedicalTriple<br>Generator   | 将实体关系转换为三元组，并按可靠性等级分流      | <code>triples</code> 、入库数量和质量记录   |
| MedicalText<br>QualityFilter | 检查医疗文本长度、特殊字符比例和重复内容       | 质量状态、过滤原因和处理统计                    |

上述算子以 `operators/*/process.py` 和 `metadata.yml` 作为可部署资产。在线建

图入口读取 DataMate 数据集后，由 `core/medical_extraction_service.py` 选择抽取后端，再由任务二服务完成校验、事务写入和分析库刷新。算子接口和在线服务共享抽取模型与校验逻辑，调用入口分别面向 DataMate 任务和数据集级 MCP 工具。

对于用户在 Nexent 中直接给出或要求生成的一段医疗文本，智能体调用统一文本抽取工具 (`extract_medical_knowledge_from_text`)。该入口只运行一次抽取链，同时返回 `entities`、`relations`、`triples`、`cascade`、`performance` 和 `extraction_errors`。返回空数组表示该段文字未识别到相应事实，仍属于结构完整的成功结果；三个拆分入口保留用于兼容单项调用，但智能体不再把同一文本重复抽取三次。自拟病历在调用前移除引号并整理为一个纯文本参数，避免对话平台把病历中的引号误判为调用语法边界。

### 4.3.1 离线词典规则抽取

离线抽取模块实现了不依赖外部模型的抽取链。

实体识别的执行过程为：第一，加载独立维护的医学词典 `entity_lexicon.json`，当前资产包含约 3.17 万条术语，词条由 CMeEE-V2 和 CMeIE 训练数据整理生成；运行时再与已有图谱实体合并，统一映射到 CMeEE 的实体类型；第二，长词优先匹配：先匹配“2 型糖尿病”再匹配“糖尿病”，已占用的字符区间不再被短词覆盖；第三，过滤停用词（“患者”“医生”“治疗”等通用词）、纯数字串、长度小于 2 或大于 32 的字符串；第四，为每个命中位置截取前后各 20 个字符作为原文片段。

关系抽取以疾病为中心，但不再把句内共现直接视为事实。模块先在同一句或受限文本窗口内定位疾病与其他实体，优先复用图谱和 CMeIE 资产中已经出现过的主客体关系；没有已知关系时，必须同时满足实体类型约束和关系触发词，例如“表现为”支持临床表现，“位于、累及”支持发病部位，“由于、导致”支持病因，“给予、服用”支持药物治疗。仅有实体共现、没有对应触发证据的候选不会直接形成关系。对于 CMeIE 常见的“疾病 @ 正文”结构，标题疾病会在同一分段的后续句中继承，使检查、部位和病因等关系仍有明确主语；遇到新的疾病标题时立即切换归属。普通病历还识别“初步诊断、入院诊断、出院诊断”等明确诊断句：诊断后的三句、360 个字符以内，给药、实施治疗和并发症枚举可以继承最近的首个诊断疾病；跨空段或遇到新的诊断句即停止继承。该窗口只解决“诊断在前一句、处理在后一句”的病历写法，不把整段任意共现实体相互连接。最后，NEGATION\_RE 检查“无”“未见”“否认”“排除”等否定表达，命中否定范围的实体不生成关系。

### 4.3.2 模型补充抽取

`core/medical_ner.py` 和 `core/medical_re.py` 将医疗记录组织为结构化抽取请求，要求模型返回实体（文本、类型缩写、起止位置）和关系（头尾实体、关系类型），均为 JSON 数组格式。模型返回的结果随后经过与离线方式相同的校验和去重管道。

### 4.3.3 离线优先级联抽取

hybrid（混合方式）采用离线优先的级联流程，先扫描全文，再根据句子覆盖情况和候选可靠性决定模型的使用范围。离线方式和混合方式的第一阶段调用同一套词典、关系规则和质量门禁。句子覆盖情况由句内已识别实体、关系以及医疗提示词共同判断：若存在未参与关系的实体、关系类型缺失或因果、部位等提示词未得到对应关系，该句进入待补充集合；没有这些情况的句子直接进入统一校验。高、中可靠离线候选直接保留；低可靠实体进入 LLM 复核；低可靠关系只放行两类窄候选：历史分组精确率达到路由条件且带原文触发词的候选，以及“明确给药句、明确诊断后续句”产生并已通过确定性证据检查的候选；旧的泛句内共现和全文上下文候选仍被门禁拦截；离线链路未覆盖但包含医疗提示词的句子进入模型补充，模型只能返回原文直接支持的实体和关系。图 4.2 展示了这条处理路径。




图 4.2 离线优先的实体关系级联抽取流程

级联流程由任务二服务负责编排。服务根据句子内实体和关系覆盖情况筛选待补充句，并限制一次模型补充的句子数量；模型调用只返回原文直接支持的实体和关系。模型补漏实体与复核恢复的低可靠离线实体共用同一套规范化门禁，统一检查原文边界、完整词形、实体类型、否定范围和噪声片段。实体的起止位置必须与原文切片逐字相等，例如原文只有“胸痛”时，“胸痛（术后）”不能通过；新增关系还必须通过端点存在性、关系类型和触发词证据校验。高分且属于已校准安全类型的候选可以直接进入合并，其余候选再与低可靠离线候选一起复核。复核通过的新增事实标记为高可靠，抽取方式字段写入 `llm_gap_verified`。其两个端点也必须通过实体校验；缺失、拒绝或不确定的决定不会新增事实。

批量处理分两阶段完成：第一阶段逐条执行离线抽取，并为每条记录加上独立候选范围；第二阶段只对存在待补充句的记录并发调用模型补充，每批最多使用 4 个工作线程，单条调用超时后保留该记录的离线结果。待补充关系、低可靠离线关系、待补充实体和低可靠离线实体按顺序进入复核队列；每一层都按记录轮转抽取候选，避免前部记录占满额度。队列上限为 256 条；随后调用 `review_candidates()` 统一处理。合并阶段以记录标识限定候选范围，避免批量处理时将其他记录的复核结果错误关联到当前记录。模型调用失败时，服务保留已经通过离线质量门禁的实体、关系和三元组，并在处理结果记录的 `llm_error` 字段中返回错误信息。因此，hybrid 在保留离线可复现结果

的同时，只把有原文依据的补充事实交给后续入库流程。

#### 4.3.4 基于可靠性分级的事实持久化

系统从 `reliability_profile.json` 读取按处理阶段、抽取方法和实体或关系类型划分的验证结果，将候选标记为高、中、低三级。配置中的分组精确率用于入库决策，表示同组方法的历史可靠性，不表示单条事实的概率。

对离线候选，分组可靠性分按

$$p_g = \frac{TP_g}{N_g}, \quad g = (s, m, c)$$

计算，其中 (s)、(m)、(c) 分别表示处理阶段、抽取方法和实体或关系类型， $N_g$  是验证集中该组输出数量， $TP_g$  是严格命中的数量。因此，同为“词典精确匹配 + 疾病”的多个实体会显示相同分数，这是按组校准的结果，不是程序把每条事实都判断成同一概率。低可靠候选经模型明确接受后，抽取方式改为 `llm_review_verified`，可靠等级提升为高，界面分数改用本次模型裁决返回值；该值仍是复核信号，不应解释为临床风险概率。

表 4.2 任务二候选事实的可靠性分级

| 等级 | 处理方式   | 写入结果                                                               |
|----|--------|--------------------------------------------------------------------|
| 高  | 通过入库校验 | 写入 <code>kg_triples</code> ，保留来源标识、原文片段和抽取方式                       |
| 中  | 保留为候选  | 写入 <code>kg_quality_issues</code> ，标记为 <code>candidate_fact</code> |
| 低  | 不进入主图谱 | 写入 <code>kg_quality_issues</code> ，标记为 <code>rejected_fact</code>  |

持久化层遇到缺失的可靠性标记时，将 LLM 结果按中等级处理，其他来源按低等级处理。这样，只有明确归入高等级的事实进入主图谱，中、低等级候选都保留在质量记录中，供复核和统计使用。

#### 4.3.5 知识构建与问答路由

知识图谱生成与问答智能体根据用户目标选择不同工具入口。用户要求处理数据集或重新建图时调用 `run_task2_kg_pipeline`；用户给出或要求生成单段医疗文本时调用 `extract_medical_knowledge_from_text`，一次取得实体、关系、三元组和性能统计；用户询问疾病属性时调用 `query_disease_analytics`；用户要求查看实体关系时调用 `query_knowledge_graph`；用户询问已登记来源时调用 `get_medical_data_sources`。

这些工具共享同一套来源、实体和关系数据，问答阶段读取的是建图阶段已经提交的事实。

建图工具和任务二服务默认使用 `hybrid` 后端，先执行离线全量扫描，再按级联规则调用模型；需要完全可复现的批量导入时，可以显式指定 `offline`。智能体根据工具返回的 `status`、来源文件摘要、生成三元组数量、入库数量和分析库刷新状态组织回答；部分记录失败或分析库未刷新时，回答保留对应状态，并将候选抽取结果与已入库事实分别展示。

## 4.4 实体关系校验与入库

抽取产生的候选依次经过类型检查、字段归一化、可靠性分级与去重，再由持久化服务完成数据库去重和写入。前四项检查由 `core/medical_extraction_validation.py` 负责，持久化服务由 `mcp_server/kg/persistence.py` 执行最终写入。

**第一道：类型校验。**实体类型只接受 9 类（疾病、症状、药物、设备、治疗、身体部位、检查、微生物、科室），通过 `ENTITY_TYPE_ALIASES` 将中文名、英文名统一映射为内部缩写；关系类型只接受 CMeIE 标准集中的 43 种，通过 `RELATION_ALIASES` 将“症状”“科室”等常见简称映射为标准名。实体文本必须在原始记录中能够定位；模型结果给出的起止位置还必须满足 `text[start:end+1] == entity.text`，位置缺失时只接受原文中唯一的精确出现，关系中的头尾实体名必须同时出现在原文中。

**第二道：归一化。**抽取侧将模型返回的各种写法统一为内部代码（实体类型“症状”→`sym`，关系别名“症状”→“临床表现”）；持久化侧（`mcp_server/kg/normalization.py`）再映射为英文关系代码和中文展示名（“临床表现”→`has_symptom`，展示名“临床表现”；“药物治疗”→`treated_by_drug`，展示名“药物治疗”）。两层归一化确保离线词典、模型和混合三种抽取方式产出的字段落在同一值域。

**第三道：可靠性分级与去重。**实体在校验函数内按出现位置和类型去重，关系按主语、谓词和宾语去重；三元组转换步骤再次按同一组合去重，并保留抽取置信度和可靠性等级。通用转换函数默认使用 0.7 的置信度下限；在线级联入口显式保留候选，最终是否进入主图谱由高、中、低三级持久化规则决定。0.7 阈值承担通用转换过滤，三级可靠性承担最终持久化分流。

**第四道：数据库去重与写入。**持久化服务按记录逐条写入：先按名称和类型保持实体唯一，再确保关系类型唯一，最后按主语、关系、宾语、来源标识和原文片段的组合写入三元组。同一名称在不同实体类型中可以分别保留，同一事实来自不同文件时各自保留独立来源标识和原文片段。三元组同时保存 `source_file` 和 `source_record_id`，查询结果可返回来源数据集、文件、记录号、原文证据、抽取方式和可靠等级。

整个抽取和入库过程由任务二服务统一编排。每条记录独立处理。某条记录的抽取失败不影响其他记录，某条三元组的写入失败也不回滚已成功入库的部分。循环结束后统计实体数、关系数、生成三元组数和实际入库数，并计算平均抽取时延和吞吐量。

### 4.5 图谱事实的分析投影

图谱写入完成后，分析刷新服务按三元组中的关系类型，将规范化事实写入面向查询的派生业务表；服务将这一步记为“分析表刷新”。`diseases` 保存疾病主表，`disease_facts` 保存全部疾病事实；症状、药物、科室、并发症、检查、治疗、病因、预防和易感人群分别进入 9 张关系表。`entity_stats` 与 `relation_stats` 保存统计结果，五个视图提供实体类型、关系类型、高频症状、科室疾病和药物疾病分布。

刷新只在图谱事务提交成功且存在新增三元组时执行，避免分析表早于图谱更新，或在没有新增事实时重复刷新。图谱库承担规范化事实和来源追溯，分析库承担疾病属性查询、分组统计与排序，图谱库作为事实和来源的规范存储，分析库作为查询和统计的派生存储，两者承担不同的数据访问职责。

### 4.6 知识图谱查询

知识图谱生成与问答智能体绑定一个建图工具和四个查询工具。建图工具（`run_task2_kg_pipeline`）接收 DataMate 数据集标识，按上述管道完成解析、抽取、入库和分析刷新，返回来源文件、格式分布、实体数、关系数、入库三元组数、各阶段耗时和吞吐量。查询工具按疾病名称读取症状、药物、检查、科室等事实，以实体为中心返回相邻节点与关系，列出已登记知识源及其记录规模。用户可以在一次对话中先启动数据集建图，再通过查询工具查看来源、疾病事实或实体关系。

### 4.7 运行实例数据构成

当前运行实例包含 14 408 个疾病条目、79 605 个实体、445 820 条三元组和 445 210 条疾病事实。表 4.3 按构建方式列出三元组来源，图 4.3 展示数量较多的关系类型。

表 4.3 运行实例三元组构成

| 构建方式              | 三元组数量   |
|-------------------|---------|
| 开放医学知识资源结构化导入     | 420 221 |
| CMeIE 标注关系导入      | 25 046  |
| DataMate 与任务二增量流程 | 553     |
| 合计                | 445 820 |




图 4.3 运行实例主要关系类型规模

运行数据中，药物关系约占全部三元组的一半，症状、检查、疾病分类和治疗关系的数量居后但仍构成主要关系类别。DataMate 增量事实作为独立来源进入同一统计口径，这些来源继续沿用同一组查询工具和分析表。

# 第五章 面向业务问题的受控分析

## 5.1 分析对象与访问入口

任务三面向疾病事实和图谱统计，支持疾病属性、实体关系、知识覆盖、来源构成和类别分布等问题。正式查询链路由一个统一分析服务承接，Nexent 任务三智能体和 Web 工作台是该服务的两个调用入口。Nexent 适合用对话提出问题，工作台适合查看查询计划、结果数据、统计图和成果文件；两者都经过同一语义规划、只读执行和结果组织流程。图谱库用于关系子图和来源登记，分析库提供疾病事实表与统计查询；统一分析服务把分析库返回的证据、图表和来源范围组织到同一分析结果中。

任务三的实现流程见图 5.1。系统先把问题转换为一个或多个查询计划，再执行安全检查和只读查询，最后形成一条可复用的分析结果记录。




图 5.1 任务三的语义规划与查询路由

图 5.1 把任务三的规划阶段拆成两条受控分支：命中确定性模板时生成九类医疗事实查询计划，未命中模板时先由语义层生成候选计划；只有在语义层判定仍需补充且模型服务可用时，才请求模型按 Schema 约束生成候选计划，然后按 SQL 和数据源去重并限制查询数量。任务三智能体在工具路由阶段再按问题类型选择知识图谱关系查询或统一只读 SQL 分析。模型服务未配置或调用失败时，系统保留可验证的语义层结果并标记降级，不会把模型未返回的内容当作查询结果。图右下角的“KG→SQL 混合分析：规划中”是后续扩展方向，不属于当前实现，也不计入本报告的评测结果。

## 5.2 基于语义规划的查询路由

医疗语义层将自然语言中的疾病名称和关系意图映射到实际业务表。系统从疾病主表中匹配名称，当多个疾病名同时出现时优先采用更长、更具体的名称。症状、药物、并发症、科室、检查、治疗、易感人群、病因和预防分别对应 9 个事实定义，每个定义明确目标表、疾病字段、结果字段、显示标题和默认排序。

“某病有哪些症状”“某病应该做哪些检查”等问题直接生成受控查询；实体类型分布、关系类型分布和科室疾病分布使用预置统计视图。对于包含多个条件或未命中模板的问题，语义层先生成可验证的候选计划；当问题仍需要开放式补充且模型服务可用时，规划器才请求模型返回受限 JSON 查询计划，并将模型计划与已识别的语义计划按 SQL 和数据源去重，最终保留最多 4 项查询。这套顺序使常用业务问题采用稳定模板，复杂表达仍可扩展到受控查询；当模型服务不可用时，结果会明确标记为降级。

任务三智能体先判断用户要求的是疾病事实、图谱关系、数据来源还是统计分析，再由任务级工具选择对应的只读能力。疾病详情、统计、排名和解释类自然语言问题统一调用 `ask_medical_analytics`，进入同一个语义规划器和分析服务；常见问题使用确定性模板，复杂问题再使用结构化查询计划。关系子图和来源清单仍由专用工具直接读取对应的图谱表，图谱关系查询与统计分析结果使用各自独立的结果口径。因此，Nexent 的对话分析和工作台的可视化结果都遵循同一结果对象契约，不会在两个入口各自维护一套自然语言查询执行逻辑。

代码上，`task3/runtime.py` 是服务装配入口。Web 工作台通过 `analysis_runtime.py` 调用它，MCP 通过 `mcp_server/tools/task3_runtime.py` 调用它。`execute_nl2sql` 保留为兼容旧智能体配置的工具名，但与 `ask_medical_analytics` 使用同一个服务实例、同一分析库和同一结果契约。`query_disease_analytics` 只保留旧调用方所需的结构化字段投影，不再作为任务三智能体的自然语言主路由。

智能体不会直接修改分析库。涉及数据接入、重新建图或刷新来源的请求，先进入任务二建图工具；涉及查询的请求只能生成单条 `SELECT` 或 `WITH` 语句，并由服务端执行表名、只读连接、时限和返回行数检查。查询失败、数据不足或问题超出当前表结构时，分析结果记录保存相应状态和口径说明，回答只引用实际返回的数据。

## 5.3 自然语言查询的只读执行

查询安全模块要求 SQL 以 `SELECT` 或 `WITH` 开头，并且只能包含一条语句。注释、数据库附加、结构修改和数据写入关键字在执行前被拦截，表名必须位于 17 个允许查询对象（14 张表和 3 个视图）的清单中。SQLite 通过 URI 只读模式打开，连接后再设置 `PRAGMA query_only=ON`。

执行器为每项查询安装 5 秒进度中止条件，最多返回 200 行；一次分析最多执行 4 项查询。每项结果保存标题、SQL、参数、列、数据行、返回数量和耗时，单项查询的状态互相独立。这些限制同时应用于语义模板和模型生成计划，并由统一分析服务对两

个调用入口执行。

### 5.4 分析结果呈现

分析服务根据查询标题与数据列组织文字回答，原始返回行同步保留为结果表。图表策略先读取用户是否明确要求图形，再根据维度类型和记录数量选择展示形式。时间字段才允许使用折线图；类别比较使用条形图或柱状图；构成比例使用环形图，并保留前 8 类、其余合并为“其他”。条形图最多展示 20 类，柱状图最多 12 类，折线图最多 16 个点。

分析结果记录包含以下内容：

- 用户问题、识别主题和查询计划；
- 每项查询的 SQL、参数、列和数据行；
- 文字回答、结果说明和数据口径；
- 图表类型、标题、维度字段、数值字段和截取规则；
- 分析标识、数据库文件名、查询数量、返回行数和执行耗时。

每次分析生成独立分析标识。页面中的回答、结果表和统计图都读取同一对象，导出模块也按该标识取得当前结果，使屏幕展示与下载文件使用相同的数据行。图 5.2 展示从问题识别、查询计划到分析结果记录的具体映射。




图 5.2 任务三的受控执行与统一结果交付

图 5.2 说明两个查询分支如何汇入同一执行结果：图谱关系查询工具面向疾病、症状、药物和科室关系，统一分析服务面向疾病详情、统计、排名和分组问题；SQL 分支

依次通过语句、对象、连接和资源检查，最后由同一分析记录驱动文字回答、数据表、图表和 HTML、CSV、JSON 导出。

图谱库与分析库承担不同职责，不能把两者的数量混写：图谱库保存规范化实体、三元组和来源，分析库保存由这些事实投影得到的疾病事实表和统计视图。因此，图中的“图谱关系查询”不表示统计 SQL 直接读取三元组表；统计、排名和分组问题仍在分析库上执行只读 SQL，具体数量以同一运行核验快照中的数据表为准。

## 5.5 知识图谱的关系浏览

关系图直接读取图谱中的实体和三元组。用户选择疾病后，系统按症状、药物、检查、科室、治疗和并发症等关系展开相邻节点。节点样式和图例在在线界面中区分实体类型，节点数较多时按关系类型与数量限制展开。导出的数据表以实体名称、关系名称、分组可靠性分和来源字段保存图中事实。对任务二增量写入的关系，来源字段包含数据集、文件名、记录号和原文证据；用户可以从图上的一条边回到任务一最终数据集中的具体文件与记录。

图谱浏览与统计分析可以在同一工作台切换。关系图适合查看具体疾病的知识结构，统计图适合比较实体类型、关系类型和来源贡献。两种展示由同一工作台组织：关系图读取图谱库，统计图读取分析库；用户能够从总体分布继续查看具体事实。

## 5.6 分析成果导出

报告模块从当前分析结果记录生成压缩包，其中包含 HTML 报告、按查询拆分的 CSV 数据和“分析追溯”JSON。HTML 保存问题、回答、查询步骤、结果表和图表说明；每项查询单独生成 CSV；JSON 保存分析计划、SQL、执行状态、来源和完整结果结构。导出口按分析标识读取页面已经展示的数据；当标识对应的结果记录不可用时，服务返回状态信息，要求重新发起分析，不会在导出阶段静默替换原结果。

HTML 适合离线阅读与成果交流，CSV 可继续进入统计工具，分析追溯 JSON 用于保存完整结果结构和接口联调。

# 第六章 系统实现与部署

## 6.1 系统运行的技术基础

作品以 Python 实现智能体工具服务和医疗领域逻辑，使用 FastMCP 暴露 MCP 接口，使用两套 SQLite 数据库分别保存知识图谱和分析表。DataMate 的数据集、文件、算子和任务状态由平台服务及 PostgreSQL 管理，Nexent 负责智能体配置、模型调用和对话执行。在线工作台采用轻量 HTTP 服务与 HTML、CSS、JavaScript，关系图和统计图在浏览器中使用 SVG 绘制。

表 6.1 主要技术与用途

| 技术或平台             | 对应架构层 | 项目用途                        |
|-------------------|-------|-----------------------------|
| Nexent            | 智能体层  | 配置三个专业智能体，绑定 MCP 工具并提供对话入口  |
| DataMate          | 服务层   | 管理数据集、文件、自定义算子和清洗任务         |
| FastMCP           | 接口层   | 注册任务一至任务三工具并返回结构化结果         |
| Python            | 服务层   | 实现格式处理、抽取校验、图谱事务、查询规划和成果导出  |
| SQLite、PostgreSQL | 数据层   | 保存图谱事实、疾病分析表和 DataMate 平台数据 |
| Docker Compose    | 部署支撑  | 组织上游平台、MCP 服务、演示服务和数据卷      |

## 6.2 代码模块组织

项目把协议入口、平台访问、业务编排、领域处理、数据存储和部署资产分开。表 6.2 给出主要代码范围。MCP 工具只负责参数接收、校验和结果返回，跨步骤流程由任务服务编排，平台调用进入客户端或适配模块，实体、关系、分析计划等结构由领域模块统一表达。

表 6.2 主要代码范围与职责

| 代码范围                                                                                              | 职责                                          |
|---------------------------------------------------------------------------------------------------|---------------------------------------------|
| clients/                                                                                          | 封装 Nexent 与 DataMate 的 HTTP 接口和身份配置         |
| mcp_server/tools/                                                                                 | 注册智能体可调用的 MCP 工具，检查参数并整理返回结构                |
| mcp_server/task1/                                                                                 | 数据集探查、混合格式编排、PDF 适配、状态和质量记录                 |
| mcp_server/task2/、<br>mcp_server/kg/                                                              | 医疗记录解析、知识抽取编排、图谱存储和分析表刷新                    |
| core/                                                                                             | 医疗抽取、九类实体校验、关系映射和图谱查询                       |
| kg/                                                                                               | 基础图谱导入、15 类关系映射和分析数据库构建                     |
| operators/                                                                                        | DataMate 可注册的医疗数据处理与知识抽取算子                  |
| task3/                                                                                            | 统一分析服务、九类疾病事实语义层、查询计划、SQL 安全、图表策略和报告生成      |
| mcp_server/tools/<br>task3_runtime.py、<br>demo/task3_<br>interactive_demo/<br>analysis_runtime.py | 分别为 MCP 与 Web 入口装配同一分析服务，复用分析库路径、来源范围和大模型配置 |
| demo/                                                                                             | 图谱浏览、数据分析和成果下载的在线工作台                        |
| deploy/、scripts/                                                                                  | 环境检查、组件安装、平台注册、服务启动和验收                      |

## 6.3 平台接入与智能体发布

DataMate 接入分为数据集访问和算子运行两部分。客户端通过平台接口解析数据集名称与标识、上传文件、读取文件清单，并登记最终交付数据集；任务服务创建算子实例与清洗任务，轮询任务状态并取得目标数据集。文件内容通过 DataMate 的文件记录和数据卷读取，数据集、任务和产物仍由平台统一管理。医疗术语整理、表格列清理、JSON 字段清理和知识抽取算子以算子代码和描述文件的形式注册到 DataMate，供任务调用。任务一在线流程直接创建 DataMate 清洗任务；任务二在线建图入口调用共享抽取服务，算子接口与该服务共用抽取模型和校验模块。

Nexent 接入分为 MCP 工具注册和智能体配置更新。部署时先在 Nexent 建立三个智能体入口并配置所用模型。发布脚本按智能体标识或名称读取当前版本，从 MCP 工具清单中解析工具标识，更新职责说明和工具绑定后发布新版本。已有对话入口可以沿

用原智能体标识，工具集合和提示内容由脚本统一更新，数据集、任务和分析标识按工具返回值传递。项目代码通过客户端和 MCP 接口连接两套上游平台，医疗领域模块保持在独立目录中。

智能体配置包含职责提示、约束提示、工具集合和可选的少样本示例。职责提示说明角色负责的业务范围，约束提示规定工具调用顺序、真实标识传递、只读边界和错误反馈，工具集合由 MCP 服务扫描结果绑定到已发布版本。这些配置决定模型能够看到哪些工具，服务端继续执行参数校验和数据库安全检查。

项目中的三个概念具有不同职责。FastMCP 是运行 MCP 服务并注册工具的服务框架；MCP 工具是智能体可以调用的一个结构化工具入口；DataMate 算子是平台内执行单个数据变换的处理单元。例如，`run_task1_mixed_cleaning` 是 MCP 工具，它在服务内部按格式创建 DataMate 清洗任务，清洗任务再组合医疗术语规范、字段清理和文本质量处理等算子。

### 6.4 系统部署架构

运行环境包括 Nexent、DataMate 等上游服务，以及 MediFlow MCP 服务、可视化服务和数据存储，见图 6.1。MCP 服务和可视化服务通过环境配置访问上游平台与数据库，数据文件保存在独立卷或项目数据目录。




图 6.1 MediFlow 运行部署关系

公开入口包括 MediFlow 工作台、Nexent 和 DataMate。工作台用于查看图谱、提交分析问题并导出成果，任务三查询进入与 Nexent 相同的统一分析服务；Nexent 提供三个专业智能体；DataMate 用于管理数据集、算子和处理任务。

### 6.5 项目交付资产

当前运行实例建立在已准备好的 Nexent 与 DataMate 环境上。仓库中的 `deploy/` 目录按顺序保存环境检查、Python 依赖、DataMate 算子注册、知识图谱与分析库构建、MCP 服务启动与工具扫描、Nexent 智能体发布、工作台启动和服务检查脚本。

部署目录同时提供分步脚本和顺序入口，可以按组件安装，也可以按完整流程执行。配置示例集中列出平台地址、数据库路径、模型接口和功能开关，服务连接参数由部署环境注入。图谱库与分析库由构建脚本生成，MCP 服务和工作台在启动时读取同一组数据库配置。

## 6.6 基于异常记录的故障定位

任务一把错误定位到文件下载、DataMate 子任务、PDF 解析或结果登记，并保留已完成格式分组的结果；任务二按记录返回解析与抽取状态，图谱写入采用事务，分析刷新只在新增事实提交后执行；任务三把计划、校验、查询和导出状态分别写入分析结果记录，各单项查询结果独立保存。对话入口和工作台读取同一结构化状态，用户可以定位到数据集、文件、记录或查询。

# 第七章 系统验证与性能评测

## 7.1 评测范围与数据来源

测试围绕三个功能阶段展开：任务一检查五类文件路由、PDF 解析适配和原有格式兼容性；任务二检查记录解析、级联抽取、可靠性分级和图谱入库；任务三使用八个在线业务场景验证语义规划、只读查询、结果组织和统计图生成，并通过 MCP 传输层核对统一分析入口和兼容入口的结果契约。任务二当前提供 40 项独立自动化回归用例；任务一、任务三按各自评测脚本另行执行；业务查询通过公开工作台接口连续请求三次并记录返回行数与响应时间。

## 7.2 智能体工具调用验证

智能体行为核验关注三个可观察结果：工具选择是否与用户目标一致，调用是否使用了真实的数据或查询参数，返回结果是否包含回答所需的结构化事实。分别执行统一医学分析查询和数据来源查询，前者选择 `ask_medical_analytics`，后者选择 `get_medical_data_sources`。两次调用均返回对应的结构化数据，最终回答仅采用工具返回的数量和医学事实。

表 7.1 代表性智能体工具路由核验

| 用户目标     | 实际选择的工具                               | 可核对结果                        |
|----------|---------------------------------------|------------------------------|
| 查询肺不张症状  | <code>ask_medical_analytics</code>    | 返回确定性查询计划、20 行证据、SQL 和分析追溯信息 |
| 查询当前登记来源 | <code>get_medical_data_sources</code> | 返回来源总数、来源列表和记录规模             |

工具路由与后端处理保持分层：智能体只选择任务级入口，工具服务负责参数校验和状态整理；任务三的查询、图表和导出统一进入分析服务，后续的算子执行、图谱事务或只读查询由确定性服务完成。因此，路由核验与任务一、任务二和任务三的功能测试分别检查不同层次。

运行态还通过 MCP 的 Streamable HTTP 接口列出 19 个工具，分别调用 `ask\_medical\_analytics` 和兼容的 `execute\_nl2sql`。同一问题两次均返回成功、确定性 NL2SQL 规划和 20 行结果，两次生成的 SQL 相同，并同时包含来源范围和执行追溯字段。工作台 `/api/query` 也返回相同的分析状态和 20 行证据。Nexent Agent 对话已实际选择 `ask\_medical\_analytics`，但当前事件流只返回最终文本，没有返回可验证的结构化分析对象；网关因此使用同一分析服务回退并标记降级。这证明了服务链路统

一；结构化事件闭环以网关返回的分析对象为核验依据，该次 Agent 对话用于验证文本回答和工具选择。

### 7.3 任务一输入路由测试

`tests/task1/test_pdf_support.py` 包含 9 项自动化用例，覆盖 PDF 接入新增逻辑及 TXT、CSV、JSON、JSONL 原有路由。测试使用模拟的 MinerU 响应，检查本地接口转换、格式路由与产物转换逻辑。全部用例执行通过，分组结果见表 7.2。

表 7.2 任务一格式与 PDF 路由测试结果

| 测试分组        | 覆盖内容                                           | 结果     |
|-------------|------------------------------------------------|--------|
| 格式路由与兼容性    | PDF 分类、二进制预览保护、原有四类格式分组、结构化处理链保持、PDF 转文本后复用文本链 | 5/5 通过 |
| MinerU 接口适配 | 签名上传与任务轮询、结果下载、Markdown 正文转换、TXT 产物与解析信息生成     | 3/3 通过 |
| PDF 服务可用性路由 | 远程解析可用性识别与处理链选择                                | 1/1 通过 |
| 合计          | 9 项测试                                          | 9/9 通过 |

这组用例覆盖的结果为：新增 PDF 分支保持了四类原有格式的分组和结构化处理链，解析产物能够转为 TXT 并继续进入既有文本清洗流程，上传、轮询和下载状态也能够转换为任务一统一结果。

### 7.4 任务一算子清洗评测

任务一采用固定生成的多格式压力集执行项目算子,用于评估清洗链在多格式输入、噪声处理和医学事实保护方面的效果。这组评测回答两个问题：清洗链能否在不同输入格式上去除非医疗内容并保留医学事实，以及噪声学习能否复用已经确认的重复表达。其中，固定噪声是 URL、HTML、Emoji、系统导出标记等可以直接匹配的内容；语义噪声是夹在医疗正文中的闲聊、交接、通知和生活描述，它们语句通顺，必须在不损伤医疗事实的前提下处理。数据集包含 TXT、CSV、JSON、JSONL 各 20 个文件,共 80 个文件、260 条记录。260 条固定噪声覆盖系统标记、链接、HTML、Emoji 和通知文字；130 条重复的语义噪声来自 3 类学习模板；26 条未见的语义噪声覆盖 5 种未参与学习的新表达。病例正文覆盖糖尿病、高血压、慢性肾脏病、慢性阻塞性肺疾病和高脂血症，同时标注症状、否定词、医学数值、姓名和病历号等必须保留的片段。金标准独立保存在旁车文件中，算子运行时只能读取原始输入。评测语料由 `evaluation/task1/stress_fixtures.py` 固定生成，

金标准保存在 `evaluation/task1/runs/operator_v2_latest/input/gold_manifest.json`。学习阶段另用 12 条已确认的语义噪声差异生成规则，基础规则和学习规则随后在同一份 260 条记录上对照。因此，这组结果用于衡量任务一清洗链在多格式输入、噪声处理、术语规范、内容保护和结构保持方面的效果。

表 7.3 任务一多格式算子清洗结果

| 指标        | 结果     | 统计对象        |
|-----------|--------|-------------|
| 清洗 F1     | 96.9%  | 噪声召回与保护率    |
| 术语准确率     | 99.1%  | 医学缩写及单位映射   |
| 字段准确率     | 97.9%  | 结构化字段与文本内容  |
| 整条记录准确率   | 88.1%  | 260 条记录     |
| 标注医学片段保留率 | 100.0% | 症状、否定、数值和标识 |
| 结构通过率     | 100.0% | 80 个文件      |

清洗 F1 是噪声召回率与医学内容保留率的调和平均，术语准确率衡量缩写和单位是否按金标准替换，字段准确率和整条记录准确率分别衡量字段级和整条记录级的一致性，结构通过率则检查文件能否重新解析且记录数、键名或列名保持一致。

图 7.1 按输入格式展开四项指标；四类链路的清洗 F1 均不低于 96.8%，术语准确率均为 99.1%。




图 7.1 多格式清洗效果。四类链路的清洗 F1 均不低于 96.8%。

“整条记录准确率”要求一条记录的所有字段都与金标准一致；只要一个字段残留噪声或标准化结果不一致，整条记录就计为错误。因此，88.1% 的记录准确率会低于 97.9% 的字段准确率，两者分别回答“整条记录是否完全匹配”和“字段是否正确”。噪声学习使用另外 12 条已确认的语义噪声差异，3 类模板各出现 4 次，最终沉淀 3 条规则。图 7.2 在同一份评测集上比较未加载和加载这 3 条规则时的召回率。固定噪声在两种配置下均为 100.0%；已学习噪声由 0.0% 提升到 100.0%；5 种未见表达仅有 3.9% 被已有规则碰巧覆盖，加入学习规则后没有变化；全部噪声召回率由 62.7% 提升到 94.0%。




图 7.2 噪声学习前后对比。柱下的  $n$  表示该类噪声在评测集中的出现次数。

该结果验证了重复噪声模板的沉淀和复用，也直接显示当前边界：精确规则不会自动理解新的闲聊表达。因此，本组数据用于验证固定规则、学习规则和结构保护机制在相同输入上的变化。

## 7.5 任务二抽取回归测试

任务二的 40 项用例覆盖级联抽取和工具层的异常保护。其中 12 项检查模型服务降级、结构化空结果、后端参数、来源记录和可靠性缺失的安全返回，21 项检查长实体匹配、诊断上下文继承、原文精确位置、分段疾病归属和缺口候选，7 项检查离线优先、批处理范围、复核决定、裁决分写回和未复核候选的入库状态。测试使用固定文本和模拟模型返回，覆盖模型降级和异常保护；本组 40 项用例在本地测试分支和服务器运行目录中分别全部通过。

表 7.4 任务二自动化测试结果

| 测试分组    | 覆盖内容                             | 结果       |
|---------|----------------------------------|----------|
| 工具防护与降级 | 模型服务异常、结构化空结果、后端校验、记录追溯和混合方式降级   | 12/12 通过 |
| 级联语义一致性 | 长实体优先、诊断上下文、分段疾病归属、精确原文范围和统一实体门禁 | 21/21 通过 |
| 级联流程与入库 | 离线优先、复核队列、裁决分写回、批处理边界和未复核候选处理    | 7/7 通过   |
| 合计      | 40 项测试                           | 40/40 通过 |

### 7.5.1 真实文本入口与跨任务衔接验证

自动化用例之外，服务器运行态执行了三种不会写入图谱的真实场景。固定病历验证单段文本入口和跨句关系；Nexent 场景要求智能体自行生成病历并在一次工具调用中返回全部指标；跨任务场景直接读取任务一已经交付的混合格式数据集。结果见表 7.5。

表 7.5 任务二真实文本入口与任务一产物衔接结果

| 场景                 | 输入规模             | 实体  | 关系 | 三元组 | 抽取耗时     | 错误 |
|--------------------|------------------|-----|----|-----|----------|----|
| 固定临床病历，统一文本入口      | 216 字符           | 14  | 6  | 6   | 8.3949 s | 0  |
| Nexent 自拟病历，一次工具调用 | 244 字符           | 22  | 1  | 1   | 7.1542 s | 0  |
| 任务一最终混合数据集，纯离线抽样   | 5 文件、33 记录中选 8 条 | 253 | 3  | 3   | 0.3377 s | 0  |

固定病历中的 6 条关系包括“2 型糖尿病 → 药物治疗 → 二甲双胍”，以及“急性心肌梗死”到阿司匹林、氯吡格雷、经皮冠状动脉介入治疗、心力衰竭和心律失常的给药、治疗与并发症关系；6 条均由离线窄规则提出候选，再经模型明确接受。Nexent 场景首次调用即成功，没有引号解析错误，也没有把空数组解释成工具异常；工具未返回的关系没有由智能体补写。

任务一最终数据集包含 CSV、JSON、JSONL、PDF 转换文本和普通 TXT 共 5 个文件。任务二实际解析出 CSV 12 条、JSONL 12 条、JSON 3 条和 TXT 6 条记录，共 33 条；跨文件抽取 8 条时，每类来源均被覆盖，抽取吞吐为 23.6897 records/s，

extraction\_errors 为空。这一结果验证任务一保持源格式的交付物可以直接被任务二使用，不需要先统一改写为 JSONL。

## 7.6 任务二抽取质量与耗时评测

### 7.6.1 评测数据与执行口径

质量评测采用 CBLUE 的 CMeEE-V2 与 CMeIE 开发集。固定留出集包含 CMeEE 2500 条记录和 CMeIE 1793 条记录，用于保留可重复的版本基线；另在两个开发集各自固定的前 100 条记录上保存同批工程回归，确保离线与混合方式处理完全相同的文本。CMeEE 实体只有在文本、起止位置和实体类型全部一致时才计为命中；CMeIE 关系只有在主语、关系类型和宾语全部一致时才计为命中。精确率表示系统输出中严格命中的比例，召回率表示人工标注事实中被系统找回的比例，F1 为二者的调和平均。

两组评测均从项目抽取服务入口执行，分别覆盖离线结果和混合补充方式。offline 使用生产质量门禁后的离线结果；hybrid 先运行完全相同的离线阶段，再对低可靠候选和规则缺口调用模型。评测设置 persist=false、refresh\_analytics=false，结果只记录评测指标；模型失败记录为错误，静默回退不计入混合成绩。

### 7.6.2 固定留出集基线

表 7.6 是统一实体门禁和分段关系修正前保存的固定留出集版本基线，用于说明完整规模上的版本基线，并与后文当前逻辑的同批对比结果分开列示。该次运行中，混合方式的实体和关系召回率及 F1 均略高于离线方式，但提升幅度有限，正是后续收紧低可靠路由、补充分段主语和统一实体门禁的依据。

表 7.6 任务二固定留出集版本基线

| 评测对象 | 方式 | 样本数   | 精确率    | 召回率    | F1     | 总耗时/s  |
|------|----|-------|--------|--------|--------|--------|
| 实体识别 | 离线 | 2 500 | 53.94% | 28.97% | 37.70% | 2.27   |
| 实体识别 | 混合 | 2 500 | 53.90% | 29.94% | 38.50% | 211.28 |
| 关系抽取 | 离线 | 1 793 | 78.67% | 7.58%  | 13.82% | 2.62   |
| 关系抽取 | 混合 | 1 793 | 78.69% | 7.73%  | 14.07% | 350.89 |

### 7.6.3 级联抽取同批对照

固定 100 条评测快照在两个数据集上对比离线与混合方式，计数与指标见表 7.7。实体识别中，混合方式在 147 个净新增实体中严格命中 105 个，召回率提高 19.23 个百分点，F1 提高 13.39 个百分点；关系抽取净新增 7 条关系，其中 6 条严格命中，召回率提高 1.95 个百分点，F1 提高 2.86 个百分点。

表 7.7 任务二级联逻辑的固定 100 条同批对比结果

| 评测对象 | 方式 | Gold | 预测  | 命中  | 精确率    | 召回率    | F1     | 混合耗时/s |
|------|----|------|-----|-----|--------|--------|--------|--------|
| 实体识别 | 离线 | 546  | 352 | 214 | 60.80% | 39.19% | 47.66% | —      |
| 实体识别 | 混合 | 546  | 499 | 319 | 63.93% | 58.42% | 61.05% | 31.85  |
| 关系抽取 | 离线 | 308  | 51  | 40  | 78.43% | 12.99% | 22.28% | —      |
| 关系抽取 | 混合 | 308  | 58  | 46  | 79.31% | 14.94% | 25.14% | 37.69  |




图 7.3 当前同批对比中离线与混合方式的精确率、召回率和 F1

图 7.3 表明，该同批结果中的混合方式不是用降低精确率换取召回率：实体识别和关系抽取的精确率、召回率与 F1 均高于同批离线结果。实体识别的主要收益来自模型发现词典未覆盖但原文明确支持的实体；关系抽取的绝对增幅较小，是因为关系仍必须同时满足疾病主语、实体端点和触发词证据，系统选择以较小但更可靠的增量避免大规模共现误判。




图 7.4 混合方式相对离线方式的净新增结果及严格标注命中情况

图 7.4 将新增结果分为“命中严格标注”和“未命中严格标注”。后者包含数据集未穷尽标注以及边界、类型口径差异，因此图中仅将严格命中计为已验证增量。两项 100 条混合评测均未出现模型调用错误；该组指标的统计范围限定为表 7.7 所列固定样本。

## 7.7 双库数据一致性核验

公开工作台的数据概览返回 14 408 个疾病条目、79 605 个实体、445 820 条三元组、445 210 条疾病事实、3 836 条质量记录和 6 个来源。基础结构化知识、CMeIE 关系与 DataMate 增量事实之和为 445 820，与图谱三元组总数一致。分析数据库按疾病事实口径生成 445 210 条记录。

表 7.8 知识库与分析库检查结果

| 检查项目   | 数量或状态         | 结果    |
|--------|---------------|-------|
| 图谱实体   | 79 605        | 可查询   |
| 图谱三元组  | 445 820       | 可查询   |
| 来源分项合计 | 445 820       | 与总数一致 |
| 疾病事实   | 445 210       | 可查询   |
| 分析成果导出 | HTML、CSV、JSON | 可用    |

## 7.8 在线查询验证

业务查询覆盖疾病的症状、检查、治疗、科室和药物五类属性，以及科室分布、实体类型分布和关系类型分布三类统计问题。每个问题在同一公开工作台接口上连续请求

三次，表 7.9 给出页面实际展示行数、三次请求的中位响应时间和波动范围。响应时间包含 HTTPS 传输、语义规划、SQLite 查询和结果组织；表中“范围”为三次请求的最小值至最大值，本表用于描述该服务实例的响应情况，解释范围限定为当前运行配置。

表 7.9 在线业务查询与响应时间

| 场景   | 测试问题               | 行数 | 中位/ms | 范围/ms     |
|------|--------------------|----|-------|-----------|
| 疾病症状 | 肺炎有哪些症状？           | 40 | 719   | 637–1 028 |
| 疾病检查 | 肺炎应该做哪些检查？         | 40 | 576   | 546–689   |
| 疾病治疗 | 肺炎有哪些治疗方法？         | 34 | 583   | 530–631   |
| 就诊科室 | 肺炎应该挂哪个科室？         | 12 | 609   | 568–610   |
| 常用药物 | 肺炎常用哪些药物？          | 40 | 824   | 747–852   |
| 科室分布 | 疾病在各科室的分布情况如何？     | 30 | 570   | 537–588   |
| 实体分布 | 医疗知识图谱中各类实体数量是多少？  | 12 | 553   | 540–580   |
| 关系分布 | 知识图谱中不同关系类型的数量是多少？ | 16 | 539   | 535–558   |

八个问题均由医疗语义层完成规划并返回结构化结果。五类疾病属性查询生成文字回答和结构化结果表，三类分布查询同时生成统计图。连续请求的中位时间位于 539–824 ms，药物与症状查询各返回 40 行；关系分布查询的观测中位数最低；表中数据用于描述总体响应，不拆分网络、规划和查询各阶段的耗时。

### 7.9 任务三 NL2SQL 执行评测

在线业务核验关注服务是否能完成一次端到端请求，NL2SQL 评测则单独检查自然语言问题能否生成可执行查询并返回正确结果。评测目录包含 133 道题：开发集 40 题，测试集 93 题；题目覆盖单表筛选、聚合统计、分组统计、Top-K 排序、多条件查询、多表联查和复杂综合七类 SQL 结构。构建脚本先在真实的 `task3_analytics.db` 上执行 Gold SQL，再保存自然语言问题和 Gold Result，因此每道题都有可复核的查询结果和数据口径。

评测主指标为执行结果准确率：系统生成的 SQL 在同一分析库执行后，返回行按多重集合比较，行内重复记录保留，顺序差异不影响判定。该指标回答的是“查询结果是否正确”，不等价于 SQL 字符串相同，也不衡量知识库检索、来源引用、图表样式或 Nexent 完整对话质量。复现入口为 `evaluation/task3/run_benchmark.py`，题目、数据库和评测输出分别保存在 `evaluation/task3/` 下。

表 7.10 任务三 NL2SQL 执行准确率与评测口径

| 运行对象    | 正确/总题数 | 执行准确率 | 口径说明               |
|---------|--------|-------|--------------------|
| 开发集验证   | 38/40  | 95.0% | 完整语义模板与结构化计划的执行结果  |
| 测试集初始配置 | 57/93  | 61.3% | 初始配置在固定测试集上的执行结果   |
| 测试集优化配置 | 89/93  | 95.7% | 优化配置在同一固定测试集上的验证结果 |

表 7.10 说明，测试集初始配置的执行准确率为 61.3%，优化配置在同一固定测试集上达到 95.7%。优化配置中，聚合统计、分组统计、多条件查询、Top-K 排序和多表联查均达到 100%；复杂综合题型达到 63.6%。这组结果验证了统一语义模板和受控查询计划对固定分析题型的覆盖能力，适用范围为本次使用的分析库、题集和配置。

表 7.11 测试集按题型的 NL2SQL 执行准确率

| 题型       | 题数 | 初始配置   | 优化配置   | 结果解释                   |
|----------|----|--------|--------|------------------------|
| 单表筛选     | 17 | 100.0% | 100.0% | 基本疾病属性查询覆盖稳定           |
| 聚合统计     | 17 | 58.8%  | 100.0% | 聚合字段和排序口径覆盖完整          |
| 分组统计     | 14 | 64.3%  | 100.0% | 分组、排序和限制条件覆盖完整         |
| 多条件查询    | 13 | 53.8%  | 100.0% | 多条件过滤和子查询覆盖完整          |
| Top-K 排序 | 12 | 83.3%  | 100.0% | 排序方向和限制条数得到统一          |
| 多表联查     | 9  | 11.1%  | 100.0% | 联接键和连接路径覆盖完整           |
| 复杂综合     | 11 | 27.3%  | 63.6%  | 多跳关联、比例和综合聚合覆盖率为 63.6% |
| 合计       | 93 | 61.3%  | 95.7%  | 固定测试集执行准确率             |

**评测结论。**任务三可以稳定处理评测集中的常见疾病属性和固定统计结构，复杂综合题型的执行准确率为 63.6%。该评测证明的是分析库上的 SQL 执行一致性，完整链路的服务验证由 Nexent 工具调用、来源解释和工作台展示结果共同构成。

7.10 分阶段性能控制

三个阶段具有不同的性能特征。任务一的时间主要由文件下载、DataMate 算子任务和 PDF 解析组成，系统按格式独立组织子任务，文件数超过 50 时转入后台；任务二按记录完成抽取与校验，写入采用数据库事务，并且只在产生新三元组时刷新分析库；任务三由统一分析服务读取本地分析数据库，通过模板或结构化计划、只读连接、5 秒中止条件和 200 行上限控制单次负载。

表 7.12 三阶段耗时记录与控制方式

| 阶段   | 主要耗时                           | 控制方式                         |
|------|--------------------------------|------------------------------|
| 数据处理 | 文件传输、DataMate 算子、PDF 版面解析、结果汇聚 | 按格式拆分任务；大数据集后台执行；保存分组进度      |
| 知识构建 | 逐记录抽取、实体关系校验、图谱写入、分析表刷新        | 轮转取样；事务写入；有新增事实时刷新分析库        |
| 分析查询 | 语义规划、SQLite 查询、回答与图表数据组织       | 模板优先；最多 4 项查询；5 秒中止；最多 200 行 |

当前八类在线查询的中位响应时间为 539–824 ms，本次观测的最大值为 1 028 ms；该结果用于描述当前服务实例的响应情况。任务一与任务二涉及外部平台、文档解析和知识抽取，系统返回结构已分别记录分组耗时、逐记录耗时、入库数量和刷新耗时，这些字段为任务一和任务二在相同数据规模、配置和部署条件下的后续比较提供统一口径。

# 第八章 关键技术创新

前面章节已经说明 MediFlow 的背景、整体设计、三项任务、实现和测试结果。本章从系统设计角度提炼七个贯穿三项任务的技术决策，说明它们分别解决了什么问题、在本项目中如何落地、以及给整个系统带来了哪些具体收益。

## 8.1 DataMate 数据与算子的 MCP 封装

赛题要求基于 Nexent 构建智能体，基于 DataMate 完成数据处理。项目实现将平台访问、领域规则 and 智能体配置拆成三层：Nexent 只负责理解用户任务和选择工具，不接触 DataMate 的接口细节；MCP 工具服务负责参数校验和结果整理，内部再调用 DataMate 客户端和领域处理模块。三个已发布智能体和自定义智能体均通过 MCP 工具名称绑定相应功能，工具的参数约定和服务端校验保持一致。

表 8.1 三层职责划分

| 层次        | 运行载体                      | 负责的内容                     |
|-----------|---------------------------|---------------------------|
| 任务理解与对话   | Nexent 智能体                | 判断用户意图、选择工具、组织回复          |
| 协议与编排     | MCP 工具服务                  | 参数检查、流程编排、结果汇总            |
| 平台执行与领域规则 | DataMate +<br>MediFlow 服务 | 数据集操作、清洗任务、知识抽取、SQL<br>安全 |

因此，DataMate 接口变化由客户端适配层承接，领域规则变化由服务模块承接，智能体配置只保存角色提示、约束提示和工具绑定。新增智能体时绑定已有 MCP 工具即可，无需在提示词中重复写入 DataMate 调用细节。

## 8.2 阶段标识驱动的结果追踪

数据处理、知识构建和分析查询三个阶段，上下游之间需要传递数据集、文件、三元组和查询表等信息。项目让每个阶段产生持久化标识，下一个阶段凭标识读取上一个阶段的结构化结果：

- 任务一向 DataMate 登记交付数据集，返回数据集标识；
- 任务二接收数据集标识，读取实际文件，入库时为每条三元组记录来源标识和文件标识；
- 任务三每次分析生成分析标识，将问题、SQL、数据行和图表说明打包为结构化对

象。

这套标识串联形成三个具体结果：第一，任务二不需要知道任务一用了哪些算子，只需要一个数据集标识就能读取清洗结果；第二，任务三的图表和导出文件均按同一个分析标识读取结果记录中的数据行；第三，三元组的来源标识可用于查询原始文件，分析标识可用于核对对应的查询计划和 SQL。

## 8.3 统一分析结果的多端复用

任务三同时面对 Nexent 对话和 Web 工作台，如果两个入口分别维护查询、图表和导出逻辑，同一个问题可能产生不同的数据口径和结果状态。项目把正式分析过程收敛到一个服务：两个入口只负责提交问题和展示结果，统一服务负责语义规划、SQL 安全、只读执行、分析标识和成果导出。

该服务先使用医疗语义模板处理高频疾病事实问题，再对多条件和长尾问题生成结构化查询计划；所有计划经过同一对象白名单、连接模式、行数上限和超时检查。回答、结果表、统计图和导出文件均从同一分析结果记录读取，因此页面展示、对话返回和下载文件可以使用相同的数据行和执行状态。第七章将 NL2SQL 执行准确率与在线响应时间分开统计，分别说明查询结果一致性和服务调用性能。

## 8.4 离线优先的级联抽取

医疗实体和关系抽取是任务二的核心环节。将模型调用作为唯一抽取路径会带来两个实际限制：一是模型服务波动或超时时整个抽取管道会中断；二是批量处理会增加模型调用次数和等待时间，在公开知识资源批量导入时成本很高。

MediFlow 为抽取服务提供三种执行方式：本地词典与规则、大模型、以及离线优先的级联方式。离线方式加载独立维护的约 3.17 万条医学术语词典和关系规则，不调用外部模型，识别结果在相同输入和词典版本下可复现；模型方式处理需要语义判断的文本；级联方式先完成离线全量扫描，再按候选可靠性和句子覆盖情况决定模型复核或补充的范围。三种方式通过同一组实体、关系和三元组字段提供结果，上层编排逻辑不需要区分当前使用的是哪种方式。

在批量导入公开知识时可以显式使用离线方式，减少外部模型依赖；任务二在线入口默认使用级联方式，高可靠事实直接进入统一校验，中可靠候选进入复核，低可靠候选不进入主图谱；对离线链路未覆盖但含有医疗提示词的句子，模型只返回原文直接支持的补充事实。模型服务不可用时，系统保留已完成的离线结果并返回错误状态，接口超时只影响对应的模型补充步骤。

第七章给出了固定留出集上的离线实体和关系抽取结果。这些结果用于衡量词典、规则和校验链的当前覆盖范围；级联设计把模型调用限定在缺口句和需复核候选上，同时保留离线结果的可复现性、来源字段和原文片段。

## 8.5 基于审计差异的语义噪声规则学习与复用

任务一章节说明了语义噪声在清洗链中的位置，本节进一步说明为什么要让规则从执行历史中产生。URL、HTML、系统导出标记等固定噪声可以由确定性规则处理，但真实病历还会混入科室交接、闲聊、通知和模板化备注。这类内容字面上是通顺的句子，不能只按特殊字符删除；如果每份文件都重新交给模型判断，同类内容会重复消耗调用时间，模型输出波动也会让相同表达得到不同结果；如果直接扩大删除关键词，又可能误删症状、否定词、药物或医学数值。

这个设计的出发点是利用系统已经记录的清洗前后差异。一次模型或人工确认的删除结果本身不能说明某个表达永远是噪声，但同一片段在多份文件中重复出现，并且始终属于安全的非医疗类别，就可以成为可复核的规则候选。因此，MediFlow 先从审计记录中规范化并统计重复片段，再按四个条件逐级筛选：片段至少出现 3 次，类别属于闲聊、口语、通知、系统导出或表单元数据等安全类别，片段长度处于可控范围，且不含疾病、症状、药物、用法用量和医学数值等医疗内容。

通过筛选的片段以精确匹配规则写入独立 SQLite 规则库，同时保存规则来源、出现次数、证据和审核状态。后续清洗只复用处于启用状态的规则，规则引擎仅在匹配位置或配置范围内删除，不改写其余文本；规则库与算子代码分离，新增、停用或复核规则不需要修改算子逻辑或重新注册。这样，一次需要语义判断的清洗结果被转成可检查、可复现、可回溯的本地处理，既减少相同模板的重复模型调用，也降低了宽泛语义规则误删医学事实的风险。

第七章的对照评测验证了这条链路：另外 12 条已确认差异中，3 类重复模板各出现 4 次，最终沉淀为 3 条规则。在同一份 260 条记录上，已学习语义噪声的召回率从 0.0% 提升到 100.0%，全部噪声召回率从 62.7% 提升到 94.0%，标注医学片段保留率保持 100.0%。同时加入 5 种未参与学习的新表达后，其召回率仅为 3.9%，且学习前后没有变化。这说明当前创新点是重复噪声模板的安全沉淀和复用，不是把有限的规则数据包装成开放域语义理解；新的表达仍需经过确认和安全筛选后才能进入规则库。

## 8.6 保持结构的数据处理

项目输入同时包含 CSV 表格、JSON 对象和 JSONL 记录。系统按格式保留列名、键名、嵌套层次和记录边界，后续知识抽取继续按字段读取内容。

结构保持规则如下：CSV 清洗时保留表头和行列位置，JSON 清洗时保留键名和嵌套层次，JSONL 清洗时保留逐行记录边界。清洗完成后，汇聚步骤会对各格式产物重新解析检查：CSV 重新读取表头确认列数一致，JSON 和 JSONL 重新解析确认结构合法，通过后才登记到最终数据集。PDF 解析为文本后也保留源文件名，知识抽取时可以区分哪些事实来自文献、哪些来自表格数据。

由此，任务二在读取清洗结果时，可以按字段取特定列的内容，可以知道这条记录来自 CSV 的哪一行和哪个文件。这些信息会随来源字段和原文片段进入知识抽取结果。

## 8.7 多层只读查询防护

任务三需要根据自然语言问题执行 SQL 查询。NL2SQL 的研究重点通常放在生成 SQL 的准确率上，在一个需要公开展示的系统中，SQL 的执行安全同样关键。错误的 DELETE、多语句拼接、或者对系统表的访问，都可能造成数据损坏或信息泄露。

MediFlow 将安全限制落实在三个层面：

- **语句层**：只接受单条 SELECT 或 WITH 语句，拒绝多语句、注释注入和结构修改关键字；
- **对象层**：表名必须落在 17 个允许查询对象（14 张表和 3 个视图）的清单中，跨库附加、系统表访问和自定义函数调用在解析阶段拦截；
- **连接层**：SQLite 以 URI 只读模式打开，连接后立即设置 `PRAGMA query_only=ON`，即使前两层被绕过，数据库引擎本身也会拒绝写操作。

此外，每次分析最多执行 4 项查询、每项最多返回 200 行、每项查询安装 5 秒进度中止条件。这些限制的直接目的在于限制单次请求的资源占用，避免异常查询长时间占用数据库连接。

这套三层安全方案由统一分析服务执行，Nexent 查询工具和 Web 工作台都经过同一组规则。八类业务查询的连续三轮测试（第七章）表明，响应时间和返回行数见表 7.9。

## 第九章 开源协作与工程交付

### 9.1 团队职责与工程产出

项目采用五个成员按职责协作的方式，协作链路覆盖需求定义、数据治理、算法实现、平台集成和测试交付。每个成员对一类工程产出负责，成员之间通过数据规范、接口契约和评测结果衔接工作。

#### 9.1.1 成员 A：需求与医学建模

成员 A 将医疗场景转化为数据规范和系统验收口径，形成医学数据字典，定义疾病、症状、检查和药物等实体，统一 CMeEE-V2 的 9 类实体标签与项目的 15 类标准关系，并整理查询问题分类和验收标准。

#### 9.1.2 成员 B：数据资产与语料治理

成员 B 负责公开知识、标注数据和项目数据的整理与版本管理，整理 QASystemOn MedicalKG 等基础医学知识来源，引入 CMeIE 实体关系标注数据，使用 CMeEE 实体标注数据构建症状质检词表，维护 `entity_lexicon.json` 医学词典，并登记数据来源、数据快照和质量记录。

#### 9.1.3 成员 C：算法与算子研发

成员 C 将数据规范转化为可执行的处理能力，实现离线优先的实体关系抽取链、词典与关系规则、模型复核机制，并校验实体边界、否定范围和关系触发词。成员 C 还负责噪声审计、规则蒸馏和安全复用，以及自然语言查询模板和结构化查询规划。

#### 9.1.4 成员 D：平台集成与部署

成员 D 将算法能力接入工作台和智能体运行环境，完成 MCP 工具封装、DataMate 与 Nexent 接入、统一任务三分析服务，维护图谱库与分析库连接，并实现 SQL 只读控制、容器部署和启动脚本。

#### 9.1.5 成员 E：测试、复现与交付

成员 E 负责验证系统是否可用并保证其他成员能够复现结果，维护 133 道 NL2SQL 评测题，拆分为 40 道开发集和 93 道测试集，组织噪声学习压力集、回归测试、查询准确率、响应时间和异常场景验证，并整理 Demo 流程、部署文档、复现材料以及最终数据、脚本、截图和交付包。

**协作闭环。** 数据角色核验数据来源，医学建模角色确认医学口径，算法角色验证抽取结果，平台角色联调接口链路，测试角色复现最终结果。

代码仓按功能组织源码、配置示例、测试、部署脚本和说明文档。平台接口与真实业务场景先在运行环境完成验证，再形成可重复部署的项目资产。

## 9.2 上游能力调研与方案选型

团队先按赛题三项任务阅读 Nexent 与 DataMate 的官方文档和源代码。对 Nexent 的调研集中在智能体版本、工具扫描、MCP 绑定和对话执行；对 DataMate 的调研集中在数据集、文件记录、算子实例、清洗任务和目标数据集。结合平台接口后确定：DataMate 承载文件与算子处理，Nexent 承载三个专业智能体，项目 MCP 服务提供医疗领域功能。

随后围绕医疗数据的实际结构确定数据方案。公开疾病知识与 CMeIE 关系用于构建基础图谱，DataMate 结果作为独立来源增量写入；图谱库保存规范化事实，分析库保存面向疾病查询的派生表；Python 与 FastMCP 实现服务，SQLite 满足当前知识规模下的部署和只读分析，独立工作台集中展示图谱、统计结果与成果下载。这些选择在主体开发阶段即形成，PDF 接入、在线展示和部署脚本是在既有架构上的功能扩展。

## 9.3 开发验证流程

表 9.1 项目开发过程与主要产物

| 阶段      | 主要工作                                      | 形成的工程产物                       |
|---------|-------------------------------------------|-------------------------------|
| 需求与上游调研 | 拆解三项赛题任务，阅读 Nexent、DataMate 的目录、接口和发布机制   | 三智能体职责、平台边界与 MCP 工具划分         |
| 数据与知识底座 | 整理疾病知识和 CMeIE 关系，设计实体类型、关系编码、图谱表与分析表      | 基础知识图谱、双库结构和数据构建脚本            |
| 三项核心功能  | 实现五类文件处理、统一记录、抽取校验、增量入库、语义查询和成果导出         | 任务一至任务三领域服务与 DataMate 算子      |
| 平台集成    | 注册 MCP 工具，配置三智能体工具集合，连接 DataMate 数据集与任务接口 | Nexent 对话入口、DataMate 处理链和发布脚本 |
| 展示与交付   | 建设图谱和分析工作台，补充 PDF 接入、自动化测试、部署与报告          | 在线系统、成果下载、测试与技术文档             |

## 9.4 上游平台接入与项目功能边界

Nexent 和 DataMate 均采用 MIT 许可证<sup>[1-2]</sup>。MediFlow 通过公开接口和部署适配使用两套平台，项目重点实现医疗场景的新增功能：医疗数据处理算子、混合格式编排、知识抽取与校验、图谱和分析库构建、MCP 工具、可视化工作台及部署脚本。外部来源按上游平台、API 接入、数据来源、协议规范和方法参考分类记录，并说明对应模块与使用方式。

表 9.2 主要开源与研究来源

| 来源                                     | 类别      | 项目中的使用方式                         |
|----------------------------------------|---------|----------------------------------|
| Nexent <sup>[2-3]</sup>                | 上游平台    | 智能体配置、工具绑定、对话执行和版本发布             |
| DataMate <sup>[1]</sup>                | 上游平台    | 数据集、文件、算子和清洗任务管理                 |
| MinerU <sup>[5-6]</sup>                | API 接入  | 远程解析 PDF；项目实现接口适配和任务一衔接          |
| CBLUE <sup>[8]</sup>                   | 数据与任务定义 | 使用 CMeIE 实体关系标注数据构成图谱数据来源之一      |
| CBLUE<br>CMeEE <sup>[8]</sup>          | 数据与任务定义 | 使用 CMeEE 实体标注数据进行实体识别评测并构建症状质检词表 |
| QASystemOn<br>MedicalKG <sup>[7]</sup> | 公开医学知识  | 整理疾病知识数据，问答与分析功能由项目实现            |
| MCP <sup>[4]</sup>                     | 协议规范    | 定义 Nexent 与 MediFlow 工具服务的调用边界   |

## 9.5 代码仓交付结构

项目代码仓同时保存源码、测试、配置示例、数据库构建脚本、部署脚本、工作流文档和技术报告。目录按客户端、MCP 入口、任务服务、领域模块、数据构建、工作台和部署资产划分。上游平台地址、模型配置和数据库位置通过环境配置注入。

三个任务的返回结构也作为交付资产维护：任务一返回数据集与文件处理信息，任务二返回记录、抽取、入库和分析刷新信息，任务三返回计划、SQL、数据行和成果文件信息。同一套结构同时服务 Nexent 对话、工作台页面和部署后的接口调用。

## 第十章 系统运维方案

本章面向现有交付版本，说明运行中需要持续维护的数据、模型配置、工具接口和测试资产。性能数值和功能核验结果以第七章的测试记录为准，运行维护沿用相同的数据口径和结果结构。

### 10.1 运行维护重点

**数据与来源更新。**任务二写入知识图谱时同时保存数据集标识、文件标识、来源名称和原文片段。更新公开知识或接入新的 DataMate 数据集时，先登记数据来源和版本，再执行知识构建；分析库刷新完成后检查图谱事实数量、来源分项和疾病分析表记录是否一致。

**词典与规则维护。**医学术语词典、关系规则、否定词规则和文本噪声规则均为独立资产。新增词条或规则时保留来源、适用实体类型和更新时间，并使用固定样本检查长词匹配、实体边界、否定表达和结构化字段清洗结果。离线抽取结果的可复现性只适用于相同输入、规则资产和版本配置，混合方式的模型结果仍需记录模型配置和调用状态。

**查询工具与智能体配置。**Nexent 中的职责提示、约束提示和工具绑定应与 MCP 服务的参数定义同步维护。工具新增或字段变更后，先运行工具扫描和固定路由用例，再发布新的智能体版本；任务三由统一分析服务承接查询，继续使用只读连接、允许对象清单、单条语句和返回行数限制。

### 10.2 质量与性能维护规范

**抽取质量。**以 CMeEE、CMeIE 固定划分作为离线比较口径，分别记录实体和关系的精确率、召回率与 F1，按同义词缺失、实体边界、类型映射、关系触发词和否定表达分类整理错误样本。词典和规则每次变更只处理一类问题，并保留变更前后的评测结果，以便判断改动是否改善了目标类型。

**知识库更新性能。**对增量数据采用数据集级任务标识和记录级来源标识，只处理新增或变更文件；抽取完成后再执行一次性事务写入和分析表刷新。当数据规模继续增长时，优先检查疾病名称、实体名称、来源标识和关系类型字段的索引，并用固定数据快照比较单批处理耗时。

**查询与导出性能。**继续记录语义规划、SQL 校验、数据库查询、结果组织和文件导出的分阶段耗时。在线查询采用固定问题集、多轮重复和相同数据库快照，同时保存中位数、P95（第 95 百分位响应时间）、返回行数和失败次数；当单次查询接近 5 秒中止限制或返回量接近 200 行上限时，再针对查询模板、索引和图表截取规则进行调整。

# 附录 A 系统资产清单

本附录列出报告正文涉及的主要 DataMate 算子、MCP 工具和数据库文件。平台自带的通用文件读写组件不单独展开；同名工具在不同智能体中的重复绑定只列一次。

## A.1 任务一数据处理资产

表 A.1 任务一 DataMate 算子

| 类别      | 代表算子                                                                                                                                                               | 主要处理内容                                                       |
|---------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------|
| 基础字符处理  | EmojiCleaner、UrlRemover、GrableCharactersCleaner、InvisibleCharactersCleaner、FullWidthCharacterCleaner、TraditionalChineseCleaner、HtmlTagCleaner、WhitespaceNormalizer | 字符、链接、乱码、不可见字符、全半角、繁简体、HTML 标签和空白处理，组成各类文本输入的基础处理链           |
| 医疗术语处理  | MedicalTermNormalizer                                                                                                                                              | 依据医学缩写与别名词典进行术语规范化；未覆盖的项保留原文并记录替换信息                          |
| 语义噪声处理  | LLMNoiseFilter                                                                                                                                                     | 按独立 SQLite 规则库识别广告、联系方式、导出标记和网页尾部等文本噪声；注册名称沿用历史算子名，当前实现为规则处理 |
| 表格字段处理  | TableColumnCleaner                                                                                                                                                 | 清理 CSV 字段值并保留表头、列顺序和行列关系                                     |
| 结构化字段处理 | JsonFieldCleaner                                                                                                                                                   | 递归清理 JSON/JSONL 文本字段并保留键名与嵌套层次                               |
| 记录组织    | MedicalRecordSplitter                                                                                                                                              | 按段落和句子边界拆分医疗记录，保留源文件与分段序号                                    |

表 A.2 任务一 MCP 工具

| 工具                                           | 主要用途                     |
|----------------------------------------------|--------------------------|
| <code>upload_text_to_datamate</code>         | 将用户提供的文本注册为 DataMate 数据集 |
| <code>inspect_dataset</code>                 | 读取数据集文件清单、格式分布和数据状态      |
| <code>list_datamate_operators</code>         | 返回当前可用的 DataMate 算子及功能描述 |
| <code>run_task1_mixed_cleaning</code>        | 按文件格式创建混合数据处理任务并汇聚交付结果   |
| <code>get_task1_mixed_cleaning_status</code> | 查询异步处理任务的状态、分组进度和结果标识    |

## A.2 任务二知识构建资产

表 A.3 任务二 DataMate 算子

| 算子                                    | 主要处理内容                         |
|---------------------------------------|--------------------------------|
| <code>MedicalEntityExtractor</code>   | 医疗实体识别，支持离线词典、模型和混合方式          |
| <code>MedicalRelationExtractor</code> | 医疗关系抽取，包含规则扫描、否定词检查和模型复核       |
| <code>MedicalTripleGenerator</code>   | 将实体与关系转换为主语、关系、宾语三元组，并按可靠性等级分流 |
| <code>MedicalTextQualityFilter</code> | 检查文本长度、特殊字符比例和重复内容，输出质量状态      |

表 A.4 任务二 MCP 工具

| 工具                                                                                                                     | 主要用途                              |
|------------------------------------------------------------------------------------------------------------------------|-----------------------------------|
| <code>extract_medical_knowledge_from_text</code>                                                                       | 单次处理一段文本，统一返回实体、关系、三元组、级联统计、性能和错误 |
| <code>extract_medical_entities</code> 、 <code>extract_medical_relations</code> 、 <code>generate_medical_triples</code> | 兼容只查看单类结果的拆分入口；空数组仍返回结构化成功对象      |
| <code>run_task2_kg_pipeline</code>                                                                                     | 读取 DataMate 数据集，完成解析、抽取、入库和分析表刷新  |
| <code>inspect_dataset</code> 、 <code>get_medical_data_sources</code>                                                   | 查看输入数据集和已登记来源                     |
| <code>get_validation_frontend_status</code>                                                                            | 返回知识图谱验证工作台的入口和服务状态               |
| <code>query_knowledge_graph</code>                                                                                     | 按实体名称查询图谱中的关系事实                   |
| <code>query_disease_analytics</code>                                                                                   | 按疾病读取症状、药物、检查、科室等结构化事实            |
| <code>ask_medical_analytics</code> 、 <code>execute_nl2sql</code>                                                       | 生成分析查询计划并在只读分析库中执行                |

### A.3 任务三分析工具

任务三复用任务二的图谱和数据来源工具，并增加查询规划、分析执行与工作台状态工具。三类智能体的具体绑定关系见表 2.2；以下列出任务三可用的完整工具集合。

表 A.5 任务三 MCP 工具

| 工具                             | 主要用途                |
|--------------------------------|---------------------|
| run_task2_kg_pipeline          | 接收新数据集并执行知识构建与分析表刷新 |
| inspect_dataset                | 检查数据集状态和可处理文件       |
| get_medical_data_sources       | 查询图谱来源及其记录规模        |
| get_validation_frontend_status | 返回可视化平台入口和服务状态      |
| query_disease_analytics        | 查询疾病属性和分析表记录        |
| ask_medical_analytics          | 将自然语言问题转换为分析计划并返回结果 |
| execute_nl2sql                 | 在只读连接中执行经过校验的查询计划   |
| query_knowledge_graph          | 浏览实体关系及其来源信息        |

## A.4 数据库与结果文件

表 A.6 项目数据库与用途

| 文件                  | 内容                   | 主要使用方                  |
|---------------------|----------------------|------------------------|
| task2_medical_kg.db | 实体、三元组、关系、别名、来源和质量记录 | 任务二工具、任务三查询、可视化平台      |
| task3_analytics.db  | 疾病事实、9 张关系表、统计表与视图   | 任务三查询、统计图表、疾病问答        |
| noise_kb.db         | 431 条文本噪声检测规则        | LLMNoiseFilter 与质量记录   |
| term_kb.db          | 114 条医学缩写与别名到规范名称的映射 | MedicalTerm Normalizer |

## 参考文献

- [1] ModelEngine-Group. DataMate: an open-source data processing platform[EB/OL]. 2026. <https://github.com/ModelEngine-Group/DataMate>.
- [2] ModelEngine-Group. Nexent: an open-source platform for building and running AI agents[EB/OL]. 2026. <https://github.com/ModelEngine-Group/nexent>.
- [3] ModelEngine-Group. Nexent 软件架构与智能体开发文档[EB/OL]. 2026. <https://modelengine-group.github.io/nexent/zh/getting-started/software-architecture.html>.

- [4] Model Context Protocol. Model Context Protocol Specification[EB/OL]. 2025. <https://modelcontextprotocol.io/specification>.
- [5] Wang B, Xu C, Zhao X, et al. MinerU: An Open-Source Solution for Precise Document Content Extraction [J/OL]. arXiv preprint arXiv:2409.18839, 2024. DOI: 10.48550/arXiv.2409.18839.
- [6] OpenDataLab. MinerU: turn any PDF into LLM-ready data[EB/OL]. 2026. <https://github.com/opendatalab/MinerU>.
- [7] 刘焕勇. QASystemOnMedicalKG: 以疾病为中心的医疗知识图谱与问答系统[EB/OL]. 2018. <https://github.com/liuhuanyong/QASystemOnMedicalKG>.
- [8] Zhang N, Chen M, Bi Z, et al. CBLUE: A Chinese Biomedical Language Understanding Evaluation Benchmark[C/OL]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. 2022: 7888-7915. DOI: 10.18653/v1/2022.acl-long.544.